

Universidad de La Habana
Facultad de Matemática y Computación



**Propuesta híbrida para encontrar el
sistema de ecuaciones diferenciales lineales
con respecto a los parámetros que mejor
ajuste un conjunto de datos
para sistemas compartimentales**

Autor:

Pablo Gómez Vidal

Tutor:

MSc. Fernando Rodríguez Flores

Trabajo de Diploma
presentado en opción al título de
Licenciado en Ciencia de la Computación

junio de 2026

Repositorio del código de la tesis



A mis padres, a quienes debo todo. Este logro es tan suyo como mío.

Agradecimientos

A mis padres, Belkis y Lázaro, porque esta tesis es el reflejo de todo su esfuerzo y sacrificio. Gracias por apoyarme incondicionalmente durante todos estos años. Sin ellos, jamás habría llegado hasta aquí.

A mi novia, Ivett, por ser mi apoyo durante todo este período. Gracias por aguantar mis malos humores, celebrar cada pequeño avance y escuchar mis tertulias sobre temas oscuros.

A mi tutor Fernando, por su paciencia, exigencia y cercanía durante todo este proceso de tesis. Sus consejos no solo mejoraron este trabajo, sino que marcaron mi forma de entender el mundo de la investigación.

A mi mejor amiga, Lietty, por ser mi compañera de noches largas de café y cigarros, y por siempre confiar en que podría lograrlo, aunque pudiese quedarme calvo. Gracias por ser mi confidente durante todo este período universitario.

A mis amigos Alejandro, Jossué, Mauricio y Francisco. Gracias por las infinitas madrugadas de estudio, las risas compartidas y el apoyo mutuo. Sin ustedes, este camino habría sido mucho más cuesta arriba y, desde luego, mucho menos divertido.

Y, por supuesto, a Diego, mi dupla desde el momento cero de la carrera. Gracias por ser mi compañero en todos los proyectos, ya fueran en equipo o individuales, por todas las tardes de cocina de alta calidad, las madrugadas de proyectos y billarcito, y las mañanas, mediodías, tardes y noches de cafecitos.

Opinión del tutor

En este trabajo se aborda el problema de la identificación de sistemas de ecuaciones diferenciales ordinarias compartimentales a partir de datos con ruido mediante regresión simbólica. La principal contribución es un método híbrido que combina la flexibilidad de los algoritmos genéticos para descubrir estructuras no predefinidas con la rapidez de SINDy un algoritmo para obtener modelos dispersos. Pablo propone usar la información proporcionada por SINDy para construir una inicialización informada de la población del AG. La propuesta incorpora el enriquecimiento de características epidemiológicas, el soporte explícito para flujos con origen externo, y un algoritmo de traducción de ecuaciones dispersas a árboles de expresión que respeta las restricciones por flujo. Los resultados experimentales muestran mejoras sistemáticas en el error cuadrático medio frente al AG base, con factores de mejora que alcanzan hasta 12x en el modelo SIRD, preservando además la estructura compartimental y recuperando con robustez los parámetros clave de los flujos epidemiológicos.

Para realizar esta tesis, Pablo tuvo que incursionar en temas que no forman parte de su plan de estudios, como la regresión simbólica, el método SINDy, así como el modelado de sistemas compartimentales aplicados a la epidemiología. Además, demostró una notable capacidad para identificar y resolver problemas durante el desarrollo, como el fenómeno de flujos en sentido contrario y la no compartimentalidad de las soluciones en versiones iniciales del trabajo. Esto evidencia un pensamiento crítico y una comprensión profunda de las limitaciones de las herramientas empleadas.

Quiero resaltar la responsabilidad y la independencia con las que Pablo llevó a cabo todo el proceso de investigación. Su trabajo se caracterizó por un alto grado de exigencia y rigor, mostrando siempre una clara vocación por alcanzar la mayor calidad posible en cada aspecto del desarrollo, desde la revisión bibliográfica hasta el diseño experimental y el análisis de resultados.

Considero que estamos en presencia de un trabajo excelente, realizado por un excelente científico de la computación.



MSc. Fernando Raul Rodriguez Flores
Facultad de Matemática y Computación
Universidad de la Habana
Junio, 2026

Resumen

Esta tesis aborda el problema de identificar sistemas de ecuaciones diferenciales ordinarias compartimentales a partir de datos ruidosos mediante regresión simbólica. Como punto de partida se analizan dos enfoques complementarios: el algoritmo genético (AG), flexible para descubrir estructuras no predefinidas, y SINDy, rápido para obtener modelos dispersos pero limitado por su biblioteca y sin garantías de compartimentalidad. A partir de sus fortalezas y debilidades, se propone un método híbrido GA+SINDy que utiliza SINDy para construir una inicialización informada de la población del AG.

La propuesta introduce cuatro elementos principales: enriquecimiento de características epidemiológicas, soporte explícito para flujos con origen externo, un algoritmo de traducción de ecuaciones dispersas de SINDy a árboles de expresión del AG respetando restricciones por flujo, y una población inicial híbrida que combina copias de la semilla informada con individuos aleatorios para balancear explotación y exploración.

Como limitación, se identifica que en algunos escenarios pueden emerger flujos en sentido contrario al esperado por el modelo epidemiológico de referencia. Este comportamiento se asocia a la etapa actual de ajuste de parámetros, que prioriza el ajuste numérico y aún no impone restricciones de direccionalidad suficientemente fuertes en todos los casos.

La validación experimental se realiza sobre los modelos SIR, SIRD y SIQRD, con niveles de ruido del 0%, 5% y 10%, y 30 ejecuciones por configuración. Los resultados muestran mejoras sistemáticas del método híbrido frente al AG base en el error cuadrático medio: en SIR, factores aproximados de 1.2x, 5.0x y 3.5x; en SIRD, 12.0x, 3.6x y 2.4x; y en SIQRD, 3.9x, 2.1x y 1.7x para 0%, 5% y 10% de ruido, respectivamente. Además, el enfoque híbrido preserva mejor la estructura compartimental y recupera con mayor robustez parámetros clave de los flujos epidemiológicos. En conjunto, el método propuesto reduce el tiempo de búsqueda efectiva del AG y mejora la calidad estructural y numérica de los modelos descubiertos.

Palabras clave: regresión simbólica, ecuaciones diferenciales ordinarias, modelos compartimentales, algoritmo genético, SINDy, identificación de sistemas, epidemiología computacional.

Abstract

This thesis addresses the problem of discovering compartmental ordinary differential equation systems from noisy data using symbolic regression. Two complementary approaches are first analyzed: genetic algorithms (GA), which are flexible for discovering non-predefined structures, and SINDy, which is very fast for sparse model estimation but limited by its candidate library and without compartmental guarantees. Based on their strengths and limitations, a hybrid GA+SINDy method is proposed, where SINDy is used to build an informed initialization for the GA population.

The proposal introduces four main components: epidemiological feature enrichment, explicit support for externally sourced flows, a translation algorithm from sparse SINDy equations to GA expression trees under per-flow constraints, and a hybrid initial population that combines informed seed copies with random individuals to balance exploitation and exploration.

As a current limitation, some scenarios may exhibit flows in the opposite direction of what the reference epidemiological model prescribes. This behavior is linked to the present parameter-optimization stage, which prioritizes numerical fit and does not yet enforce sufficiently strong directionality constraints in all cases.

Experimental validation is conducted on SIR, SIRD, and SIQRD models under 0%, 5%, and 10% noise levels, with 30 runs per configuration. Results show consistent improvements of the hybrid method over the baseline GA in mean squared error: for SIR, approximate factors of 1.2x, 5.0x, and 3.5x; for SIRD, 12.0x, 3.6x, and 2.4x; and for SIQRD, 3.9x, 2.1x, and 1.7x at 0%, 5%, and 10% noise, respectively. In addition, the hybrid approach better preserves compartmental structure and more robustly recovers key epidemiological flow parameters. Overall, the proposed method reduces the effective GA search burden and improves both the structural and numerical quality of the discovered models.

Keywords: symbolic regression, ordinary differential equations, compartmental models, genetic algorithm, SINDy, system identification, computational epidemiology.

Índice general

Introducción	1
1. Preliminares	5
1.1. Sistemas de Ecuaciones Diferenciales Ordinarias	5
1.1.1. Sistemas lineales con respecto a los parámetros	6
1.2. Sistemas de Ecuaciones Diferenciales Ordinarias Compartmentales .	7
1.3. Regresión Simbólica	8
1.4. Regresión Simbólica en EDOs	9
1.5. Algoritmos genéticos	10
1.6. SINDy: identificación dispersa de dinámicas no lineales	11
2. Metodología	13
2.1. Algoritmo Genético para Regresión Simbólica de Sistemas Comparti- mentales	13
2.1.1. Representación de sistemas mediante árboles de expresión . .	14
2.1.2. Representación de sistemas compartimentales mediante grafos	17
2.1.3. Modificación de árboles: búsqueda sobre aristas	18
2.1.4. Función de costo y estimación de parámetros	20
2.1.5. Operadores genéticos y ciclo evolutivo	22
2.2. SINDy: Identificación Dispersa de Dinámicas No Lineales	23
2.3. Fundamentos de SINDy	24
2.3.1. La biblioteca de funciones	24
2.3.2. El principio de esparcidad	25
2.4. Ventajas frente al enfoque evolutivo	25
2.5. Aplicación al modelo SIR: resultados y análisis	26
2.6. Limitaciones estructurales de SINDy	28
3. Propuesta	29
3.1. Enriquecimiento de características	30
3.1.1. Ejemplo: modelo SIRD con natalidad	31
3.2. Flujos externos	32

3.3.	Traducción de ecuaciones SINDy a flujos del AG	33
3.3.1.	Ejemplo: traducción del modelo SIRD	35
3.3.2.	Traducción flujo por flujo	36
3.4.	Población inicial híbrida	37
3.4.1.	Composición de la población	38
3.4.2.	Diversificación y evolución	38
3.5.	Algoritmo completo	39
4.	Resultados y experimentos	41
4.1.	Descripción del marco experimental	41
4.2.	Modelo SIR	43
4.2.1.	Comparación de ECM por método y nivel de ruido	43
4.2.2.	Nivel de ruido: 0 %	44
4.2.3.	Nivel de ruido: 5 %	45
4.2.4.	Nivel de ruido: 10 %	46
4.2.5.	Discusión SIR	47
4.3.	Modelo SIRD	47
4.3.1.	Comparación de ECM por método y nivel de ruido	47
4.3.2.	Nivel de ruido: 0 %	48
4.3.3.	Nivel de ruido: 5 %	49
4.3.4.	Nivel de ruido: 10 %	50
4.3.5.	Discusión SIRD	51
4.4.	Modelo SIQRD	52
4.4.1.	Comparación de ECM por método y nivel de ruido	52
4.4.2.	Nivel de ruido: 0 %	53
4.4.3.	Nivel de ruido: 5 %	54
4.4.4.	Nivel de ruido: 10 %	55
4.4.5.	Discusión SIQRD	56
4.5.	Análisis contrafactual de los flujos inversos de I a S	57
4.5.1.	Caso SIRD (ruido 10 %)	57
	Conclusiones	59
	Recomendaciones	61
	Bibliografía	62

Índice de figuras

1.1. Grafo del modelo compartimental SIR.	8
2.1. Estructura de árbol que representa una ecuación diferencial lineal respecto a los parámetros. La raíz es un nodo de suma que agrupa todos los términos de la ecuación.	15
2.2. Estructura de un término de la ecuación. Cada término es un producto de un parámetro (nodo hoja) por una función que solo depende de las variables de estado (subárbol derecho).	16
2.3. Representación en árbol del modelo SIR completo. El nodo raíz SYSTEM agrupa las tres ecuaciones, cada una descompuesta como suma de términos.	16
2.4. Ejemplo de grafo dirigido que representa un sistema compartimental con tres compartimentos A , B y C . Las aristas (A, B) y (B, C) representan los flujos entre compartimentos.	17
2.5. Grafo dirigido del modelo SIR. La arista $S \rightarrow I$ lleva la expresión $k_{SI} = \beta SI$ que representa el flujo de susceptibles que se infectan, y la arista $I \rightarrow R$ lleva la expresión $k_{IR} = \gamma I$ que representa el flujo de infectados que se recuperan.	18
2.6. Representación en árbol original del modelo SIR: un hijo por ecuación. La raíz tiene tres subárboles correspondientes a las tres ecuaciones del sistema.	19
2.7. Representación en árbol alternativa del modelo SIR: un hijo por arista. La raíz tiene dos subárboles correspondientes a las dos aristas del grafo. Esta representación reduce los árboles buscados de tres a dos y garantiza por construcción que el sistema resultante sea compartimental.	20
2.8. Modelo SIR: datos de entrenamiento y ajuste de SINDy. La solución integrada a partir del sistema identificado reproduce fielmente la trayectoria observada.	27

3.1.	Comparación de representaciones del modelo SIRD con natalidad. (a) La formulación estándar solo permite flujos entre compartimentos internos, haciendo imposible capturar el término de natalidad constante. (b) La nueva contribución permite flujos externos mediante $src = \text{None}$ (arista discontinua azul), representando procesos que incorporan individuos desde fuera del sistema. Los cuatro flujos del modelo son: f_0 (transmisión $S \rightarrow I$), f_1 (recuperación $I \rightarrow R$), f_2 (mortalidad $I \rightarrow D$), y f_3 (natalidad $\text{None} \rightarrow S$).	33
4.1.	Marco experimental del modelo SIR: datos originales, datos con ruido y datos suavizados mediante spline.	43
4.2.	Datos con diferentes niveles de ruido en el modelo SIR.	43
4.3.	SIR sin ruido: mejor ejecución de cada método.	44
4.4.	SIR con ruido 5 %: mejor ejecución de cada método.	45
4.5.	SIR con ruido 10 %: mejor ejecución de cada método.	46
4.6.	Datos con diferentes niveles de ruido en el modelo SIRD.	48
4.7.	SIRD sin ruido: mejor ejecución de cada método.	48
4.8.	SIRD con ruido 5 %: mejor ejecución de cada método.	50
4.9.	SIRD con ruido 10 %: mejor ejecución de cada método.	51
4.10.	Datos con diferentes niveles de ruido en el modelo SIQRD.	52
4.11.	SIQRD sin ruido: mejor ejecución de cada método.	53
4.12.	SIQRD con ruido 5 %: mejor ejecución de cada método.	55
4.13.	SIQRD con ruido 10 %: mejor ejecución de cada método.	56
4.14.	Análisis contrafactual en SIRD: original vs sistema descubierto vs sistema sin flujo $I \rightarrow S$	57

Introducción

Las ecuaciones diferenciales ordinarias describen la evolución continua de fenómenos y son fundamentales en diversas áreas científicas y de ingeniería. Se emplean en física para representar el cambio en sistemas dinámicos [1]; en química, modelan la cinética de reacciones, permitiendo la predicción de concentraciones de sustancias [2]; y en biología, se utilizan para el análisis del crecimiento poblacional, la interacción entre especies y la propagación de enfermedades [3]. Adicionalmente, en economía, estas ecuaciones facilitan la representación de dinámicas de crecimiento y fluctuaciones de mercado [4], mientras que el análisis de sus soluciones es crucial para el diseño y control de sistemas en ingeniería [5]. Las ecuaciones diferenciales proporcionan un marco para la validación de hipótesis y la elaboración de predicciones.

En el contexto de las dinámicas poblacionales, las EDOs se utilizan con frecuencia para describir cómo interactúan distintos grupos de individuos a lo largo del tiempo, dando lugar a los llamados modelos compartimentales [6]. En esencia, estos modelos dividen a la población total en subgrupos o compartimentos excluyentes según su estado, por ejemplo, personas susceptibles, infectadas o recuperadas; y utilizan las ecuaciones para calcular matemáticamente cómo transitan los individuos de un grupo a otro. Estos enfoques resultan especialmente útiles en áreas como la epidemiología, donde permiten analizar la propagación de enfermedades infecciosas, así como en otros campos donde interese observar cómo cambia una población bajo diferentes escenarios.

La construcción de modelos basados en EDOs requiere un conocimiento previo del sistema bajo estudio, de manera que la estructura de las ecuaciones diferenciales se define a partir de principios teóricos o empíricos, y posteriormente se ajustan sus parámetros a partir de datos observacionales [7]. Sin embargo, en muchos escenarios reales esta información no está disponible frecuentemente [8] debido a que los mecanismos de interacción son demasiado complejos o se trata de dinámicas emergentes, como una enfermedad infecciosa nueva, cuya teoría aún no está consolidada, y únicamente se cuenta con mediciones del comportamiento del sistema a lo largo del tiempo [9].

Un problema central es el de la identificación de modelos dinámicos a partir de datos: inferir automáticamente las ecuaciones diferenciales que describen la dinámica

observada [10, 11]. Dicha tarea resulta particularmente desafiante en los modelos compartimentales, pues no solo se requiere ajustar parámetros numéricos, sino también determinar la estructura del sistema, es decir, las interacciones entre compartimentos y las tasas de transición entre ellos sin disponer de una forma funcional predefinida [12].

Diversos enfoques han sido propuestos para abordar el problema del descubrimiento de ecuaciones diferenciales a partir de datos. Entre ellos, la regresión simbólica constituye una de las aproximaciones más relevantes, ya que permite identificar expresiones matemáticas que describen la relación entre variables sin asumir una forma funcional predefinida. Dentro de las técnicas de regresión simbólica, los métodos basados en algoritmos genéticos han sido utilizados para inferir estos sistemas [13, 14]. Además, se han propuesto enfoques que logran garantizar matemáticamente la estructura biológica de los modelos compartimentales [15]. Sin embargo, a pesar de su precisión topológica, estos enfoques puros basados en metaheurísticas siguen presentando vulnerabilidad ante el ruido [16, 17] y dificultades para garantizar su convergencia en un tiempo computacional práctico, especialmente en sistemas complejos debido a la alta dimensionalidad de la búsqueda [18].

Como alternativa, han surgido métodos basados en la hipótesis de que muchos sistemas dinámicos pueden representarse mediante un número reducido de términos relevantes. En este contexto, el método *Sparse Identification of Nonlinear Dynamics* (SINDy) propone construir una biblioteca de funciones candidatas y emplear técnicas de regresión dispersa para identificar las ecuaciones que mejor describen los datos observados [11]. Este enfoque ha demostrado ser eficiente y producir modelos interpretables, aunque su desempeño depende en gran medida de la selección adecuada de la biblioteca de funciones y puede verse afectado por la presencia de ruido en los datos [19].

A pesar de los avances logrados, detectar automáticamente modelos compartimentales a partir de datos de poblaciones sigue siendo todo un desafío. El problema central que aborda este trabajo es que la mayoría de los métodos actuales para descubrir ecuaciones no tienen en cuenta, de manera explícita, ciertas reglas básicas que debe cumplir una población, como que el número total de individuos se conserva o que los movimientos entre grupos deben estar equilibrados. Ignorar estas reglas, que son sensatas desde lo físico y lo biológico, puede llevar a obtener ecuaciones que se ajusten muy bien a los números observados, pero que en realidad describen modelos que no tienen sentido para el fenómeno que se está estudiando.

Frente a este panorama, surge la siguiente pregunta científica: ¿Qué enfoque entre la programación genética y SINDy permite identificar con mayor precisión y eficiencia la estructura de un modelo compartimental a partir de datos poblacionales, respetando sus restricciones biológicas? y, complementariamente, ¿es posible combinar las fortalezas de ambos enfoques en un método híbrido que supere las limitaciones indivi-

duales de cada uno y mejore la identificación automática de modelos compartimentales a partir de datos?

El objetivo general de este trabajo es comparar dos enfoques para el descubrimiento de ecuaciones diferenciales ordinarias compartimentales a partir de datos evaluando su precisión y capacidad para respetar las restricciones estructurales propias de los modelos poblacionales, y proponer un método híbrido que combine las fortalezas de ambos enfoques con el fin de mejorar la identificación automática de modelos compartimentales a partir de datos.

Para lograr este fin, se han trazado los siguientes objetivos específicos:

- Estudiar la bibliografía y técnicas fundamentales para la regresión simbólica orientada al descubrimiento de EDOs.
- Analizar las propiedades y fundamentos teóricos de las EDOs utilizadas para describir dinámicas compartimentales.
- Estudiar técnicas alternativas, no basadas exclusivamente en metaheurísticas, como la regresión dispersa, para la resolución de este problema.
- Realizar un estudio comparativo entre los enfoques analizados para evaluar su eficacia y respeto por las restricciones estructurales biológicas.
- Diseñar y evaluar un método híbrido que integre la programación genética y SINDy, aprovechando las fortalezas de ambos enfoques para mejorar la identificación de modelos compartimentales a partir de datos ruidosos.

La estructura de este documento es la siguiente: en el Capítulo 1 se introducen los fundamentos teóricos necesarios para comprender y abordar el problema. En él se abarcan desde los conceptos matemáticos de las ecuaciones diferenciales ordinarias y los modelos compartimentales, hasta las bases computacionales de la regresión simbólica y los métodos contemporáneos para la detección de ecuaciones, tales como algoritmos genéticos y SINDy. En el Capítulo 2 se describe la metodología empleada, explicando a fondo los dos enfoques computacionales base: el funcionamiento interno de la programación genética aplicada a la regresión simbólica, y la regresión lineal dispersa mediante el algoritmo SINDy, así como la propuesta del método híbrido que los integra. Posteriormente, en el Capítulo 3 se presentan los experimentos realizados y el análisis comparativo de los resultados obtenidos por los distintos enfoques, incluido el método híbrido propuesto. Finalmente, se exponen las conclusiones derivadas de la investigación, así como las recomendaciones y posibles líneas de trabajo futuro.

Además, es importante mencionar el papel de la tecnología en el desarrollo de este trabajo. Debido al gran avance y disponibilidad de las herramientas digitales modernas, el uso de la inteligencia artificial se volvió un recurso clave para la revisión de la

literatura. Su aplicación facilitó la búsqueda y organización de la información en bases académicas de datos, haciendo posible encontrar bibliografía accesible, de calidad y estrictamente actualizada. De esta manera, el uso estratégico de las herramientas de automatización inteligente ayudó a construir un marco teórico sólido y actualizado con las últimas publicaciones de la materia, respondiendo de forma eficiente a los retos actuales de la investigación académica. La opinión del tutor presentada en este documento fue generada (por el tutor) usando modelos grandes de lenguaje, en particular DeepSeek. Para ello se usó el resumen de la tesis y las características personales del estudiante que resultaron relevantes para el desarrollo del trabajo. Para alcanzar el tono propio del tutor, se proporcionaron como ejemplos los mismos elementos (resumen de la tesis y características del estudiante) de opiniones del tutor de cursos anteriores.

Capítulo 1

Preliminares

Este capítulo presenta los conceptos teóricos que sustentan el resto del trabajo. Se introducen los sistemas de ecuaciones diferenciales ordinarias y, en particular, los sistemas compartimentales empleados en la modelación de epidemias. A continuación se formaliza el problema de la regresión simbólica y, dentro de este, el de la identificación de EDOs a partir de datos observados. Finalmente, se revisan las familias principales de métodos que abordan este problema y se discute la restricción de linealidad en los parámetros, común a los enfoques desarrollados en los capítulos posteriores.

1.1. Sistemas de Ecuaciones Diferenciales Ordinarias

Un sistema de ecuaciones diferenciales ordinarias es un conjunto de una o más ecuaciones que relacionan una función desconocida o un conjunto de funciones con respecto a una única variable independiente, a través de sus derivadas [20, 21]. Este tipo de sistemas describe cómo cambia una o varias cantidades en el tiempo, según una dinámica especificada por funciones conocidas.

Matemáticamente, un sistema de n EDOs de primer orden puede escribirse como:

$$\begin{aligned}\frac{dx_1}{dt} &= f_1(t, x_1, x_2, \dots, x_n) \\ \frac{dx_2}{dt} &= f_2(t, x_1, x_2, \dots, x_n) \\ &\vdots \\ \frac{dx_n}{dt} &= f_n(t, x_1, x_2, \dots, x_n)\end{aligned}$$

donde $x_1(t), x_2(t), \dots, x_n(t)$ son funciones desconocidas que dependen de la variable

independiente t , y $f_1, f_2, \dots, f_n$ son funciones conocidas que describen las tasas de cambio de cada variable. Para obtener una solución específica del sistema, es necesario fijar condiciones iniciales del tipo $x_i(t_0) = x_{i,0}$, que determinan el estado del sistema en un instante inicial t_0 .

Ahora se introduce un caso particular que será útil en los métodos del capítulo siguiente: los sistemas lineales con respecto a los parámetros.

1.1.1. Sistemas lineales con respecto a los parámetros

Un sistema de EDOs es lineal en los parámetros cuando las funciones de la parte derecha pueden escribirse como una combinación lineal de parámetros:

$$f(t, \mathbf{x}(t)) = \theta_1 g_1(t, \mathbf{x}(t)) + \theta_2 g_2(t, \mathbf{x}(t)) + \dots + \theta_p g_p(t, \mathbf{x}(t)), \quad (1.1)$$

donde $\theta_i \in \mathbb{R}$, $\mathbf{x}(t) = (x_1(t), x_2(t), \dots, x_n(t))$ y $g_i(t, \mathbf{x}(t))$ son funciones de t y $\mathbf{x}(t)$. Las funciones $g_i(t, \mathbf{x}(t))$ se llaman términos de $f(t, \mathbf{x}(t))$.

Este tipo de estructura aparece en sistemas clásicos como el SIR [22]. Por ejemplo:

$$\begin{aligned} \dot{S} &= -aSI, \\ \dot{I} &= aSI - bI, \\ \dot{R} &= bI, \end{aligned}$$

donde S, I, R son las variables dependientes y a, b son parámetros. Este sistema es lineal con respecto a los parámetros a y b porque sus ecuaciones tienen la forma que se describe en la ecuación (1.1).

Por ejemplo, en la ecuación:

$$\dot{I} = aSI - bI$$

se puede comprobar que el lado derecho es de la forma

$$\dot{I} = a g_1(t, S, I, R) - b g_2(t, S, I, R),$$

con $g_1(t, S, I, R) = SI$ y $g_2(t, S, I, R) = I$. De la misma forma, las ecuaciones de las derivadas de las variables S y R son lineales con respecto a los parámetros, por lo que el sistema es lineal con respecto a los parámetros.

Con esta estructura lineal en parámetros establecida, el siguiente paso es considerar una familia con interpretación directa en términos de flujos entre estados: los sistemas de EDOs compartimentales.

1.2. Sistemas de Ecuaciones Diferenciales Ordinarias Compartmentales

Los sistemas de EDOs compartimentales son una herramienta matemática utilizada para describir la evolución de una cantidad que se distribuye entre distintos estados o compartimentos. Cada compartimento representa una parte diferenciada del sistema que se desea modelar, como puede ser un grupo de individuos en una población, una fase en un proceso químico o un estado de salud en una enfermedad [23, 24]. Entre estos compartimentos existe un flujo que indica cómo la cantidad se transfiere de uno a otro.

Este tipo de modelos se emplea en ecología para representar la interacción entre especies [25], en ingeniería química para modelar procesos de transporte de sustancias [26], y en epidemiología para estudiar la propagación de enfermedades [27]. En este último caso, uno de los modelos más conocidos es el modelo SIR, que clasifica a la población en tres compartimentos: susceptibles, infectados y recuperados. Las ecuaciones que describen su dinámica son:

$$\frac{dS}{dt} = -\beta SI, \quad (1.2)$$

$$\frac{dI}{dt} = \beta SI - \gamma I, \quad (1.3)$$

$$\frac{dR}{dt} = \gamma I, \quad (1.4)$$

donde:

- S es la población susceptible,
- I es la población infectada,
- R es la población recuperada,
- β es la tasa de transmisión,
- γ es la tasa de recuperación.

Una forma natural de representar los compartimentos de un sistema y los flujos entre ellos es mediante grafos dirigidos, en los cuales los nodos corresponden a los compartimentos y las aristas representan las transferencias o interacciones entre ellos [28]. La Figura 1.1 muestra un ejemplo del modelo SIR representado mediante un grafo.

A partir del grafo definido, se construye un sistema de ecuaciones diferenciales ordinarias que describe la evolución temporal de cada compartimento. La presencia de una arista dirigida desde el nodo X hacia el nodo Y indica que existe un flujo desde X hacia Y ; este flujo debe modelarse como una pérdida en la ecuación de X , término negativo, y una ganancia en la de Y , término positivo. La ausencia de una conexión entre dos compartimentos implica que no existe interacción directa entre ellos, lo cual se refleja en las ecuaciones como la falta de términos que involucren simultáneamente a ambas variables.




Figura 1.1: Grafo del modelo compartimental SIR.

Es fundamental que la modelación de estos flujos preserve coherencia en la representación matemática: cada transferencia entre compartimentos debe estar reflejada simétricamente como salida en una ecuación y entrada en otra. Si un flujo aparece restando en una ecuación pero no sumando en otra, se estaría introduciendo una pérdida neta de cantidad sin justificación física o biológica, lo cual constituye un error en la formulación del modelo compartimental. Esta correspondencia entre el grafo y el sistema de ecuaciones asegura, por ejemplo, la conservación de la cantidad total cuando el sistema así lo requiere, y ofrece además una interpretación estructural clara del proceso dinámico.

Cabe mencionar que también pueden existir flujos externos que no provienen de otro compartimento, como nacimientos en una población o entradas de materia desde una fuente externa. En estos casos, el término correspondiente se incorpora directamente en la ecuación del nodo de destino, sin necesidad de que exista otro nodo de origen en el grafo.

1.3. Regresión Simbólica

La regresión simbólica es un tipo de análisis de regresión que explora el espacio de expresiones matemáticas para encontrar el modelo que mejor se ajuste a un conjunto de datos determinado, tanto en términos de precisión como de simplicidad [29]. Para la regresión simbólica no se proporciona ningún modelo particular como punto de partida. En cambio, las expresiones iniciales se forman combinando aleatoriamente elementos matemáticos como funciones analíticas, operadores matemáticos y constantes [30].

Durante mucho tiempo, la regresión simbólica se utilizaba únicamente en el dominio de los seres humanos. John R. Koza fue uno de los primeros en proponer un método para utilizar la regresión simbólica mediante computadoras [30], con el uso de árboles computacionales para codificar expresiones matemáticas. En estos árboles, los nodos interiores representan operadores y funciones ($+$, $-$, $*$, e^x , $\text{sen}(x)$, etc.), pertenecientes a un conjunto de funciones posibles, y los nodos hoja representan las variables y constantes ($x_1, x_2, \dots, -1, \pi$, etc.) [31].

El problema de regresión simbólica se puede definir matemáticamente de la siguiente manera: dado un conjunto P de funciones, una distancia $L : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}^+ \cup \{0\}$, vectores $x_i = (x_{1,i}, \dots, x_{d,i}) \in \mathbb{R}^d$ y escalares $y_i \in \mathbb{R}$, para $i = 1, \dots, n$, el problema busca encontrar una función f^* tal que:

$$f^* \in \arg \min_{f \in F} \left(\frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i)) \right), \quad (1.5)$$

donde F es el espacio de expresiones construibles a partir de P [31].

El problema de regresión simbólica es un problema NP-difícil [31], lo que significa que no siempre es posible encontrar la solución en tiempo polinomial. Para resolver el problema de regresión simbólica, se han abordado varios enfoques como el método bayesiano [32], el recocido simulado [33] y los algoritmos genéticos [29]. También existen bibliotecas para el uso de la regresión simbólica. Entre ellas se encuentra *gplearn*, una biblioteca de código abierto desarrollada en *Python* [34], y *TuringBot*, un software que utiliza recocido simulado [33].

Otro enfoque para abordar la regresión simbólica es el uso de redes neuronales. Ejemplo de ello es el software *AI Feynman*, que busca describir ecuaciones a través de datos derivados de observaciones y que ha demostrado ser eficaz en el dominio de las ecuaciones físicas [35, 36].

La regresión simbólica ha resultado útil en diferentes investigaciones para determinar el sistema de ecuaciones diferenciales ordinarias que mejor describen un conjunto de datos [37-39]. El problema de regresión simbólica en ecuaciones diferenciales ordinarias está orientado a encontrar funciones desconocidas que representan el lado derecho de una ecuación diferencial. En la siguiente sección se describe el problema de regresión simbólica en ecuaciones diferenciales ordinarias.

1.4. Regresión Simbólica en EDOs

Los sistemas de ecuaciones diferenciales constituyen una herramienta fundamental para representar y analizar diversos procesos que ocurren en la naturaleza y la sociedad [40-42]. Sin embargo, en muchas situaciones, aunque se disponga de datos que describen un fenómeno específico, no resulta evidente cuál es el sistema de ecuaciones

que mejor lo representa. Por ello, sería valioso contar con mecanismos que permitan encontrar este modelo.

El problema de regresión simbólica en ecuaciones diferenciales ordinarias consiste en encontrar la parte derecha de una ecuación diferencial ordinaria cuya solución sea una función que describa un conjunto de datos. Se puede definir el problema como dado un conjunto de datos de la forma $\{(t_i, y_i), i = 1, \dots, n\}$, encontrar la función $f(t, y(t))$ tal que la solución de:

$$\frac{dy}{dt} = f(t, y(t)),$$

sea una función y tal que $y(t_i) \approx y_i, \forall (t_i, y_i) \in N$. Esta definición se puede extender a sistemas de ecuaciones diferenciales ordinarias.

Se define matemáticamente el problema de la siguiente manera: dado un conjunto de datos $\{(t_i, y_i), i = 1, \dots, n\}$:

$$\min_{f \in \mathbb{T}_F} \sum_{i=1}^n (y(t_i) - y_i)^2 + \text{penalization}(f)$$

$$s.a : y' = f(t, y), y(t_0) = y_0,$$

donde $\mathbb{T}_F$ representa el conjunto de todas las funciones de dos variables que se pueden representar mediante árboles, y *penalization* es una función que penaliza alguna característica en los modelos, como por ejemplo la complejidad de la expresión resultante, que se puede calcular como la cantidad de nodos del árbol.

Uno de los métodos utilizados para resolver el problema de regresión simbólica son los algoritmos genéticos [29, 39], que serán presentados en la siguiente sección.

1.5. Algoritmos genéticos

Las metaheurísticas son estrategias generales de optimización diseñadas para abordar problemas complejos en los que los métodos exactos resultan inviables [43]. Entre ellas figuran el recocido simulado [44], la búsqueda tabú [45] y los algoritmos genéticos (AG) [46].

Los AG están inspirados en los principios de la evolución natural [29, 47]: operan sobre una población de soluciones candidatas, donde cada individuo representa una posible expresión matemática. La población evoluciona iterativamente mediante operadores de selección, cruce y mutación, con el objetivo de mejorar la calidad de las soluciones. Esta calidad se mide a través de una función de aptitud, la cual asigna a cada solución un valor de aptitud, conocido como *fitness*, que cuantifica qué tan buena es con respecto a la función objetivo.

Aplicado a regresión simbólica de EDOs, esto significa que cada individuo de la población representa una propuesta de sistema de ecuaciones. En cada generación, el algoritmo compara esas propuestas con los datos observados y conserva las que describen mejor la dinámica del fenómeno, descartando gradualmente las menos útiles. De este modo, AG y regresión simbólica se combinan para buscar no solo buenos parámetros, sino también una forma funcional adecuada del modelo [48, 49].

En términos prácticos, la principal fortaleza de los algoritmos genéticos es su flexibilidad: pueden explorar espacios de búsqueda muy amplios y no lineales sin imponer una forma funcional fija desde el inicio. Esto los hace adecuados cuando se desconoce la estructura real del modelo o se espera una dinámica compleja [29, 43].

No obstante, esa misma flexibilidad tiene un costo. La exploración evolutiva suele requerir muchas evaluaciones, por lo que el tiempo de cómputo puede ser alto y la convergencia lenta. Esta limitación motiva el interés por métodos más eficientes en tiempo de ejecución, como SINDy, que se presenta a continuación.

1.6. SINDy: identificación dispersa de dinámicas no lineales

El método *Sparse Identification of Nonlinear Dynamics* (SINDy), propuesto por Brunton et al. [50], ofrece una alternativa para la identificación de sistemas dinámicos. Su hipótesis central es que muchas dinámicas naturales pueden expresarse como un conjunto de funciones candidatas que se fija antes del ajuste y que normalmente incluye elementos simples como constantes, variables, productos entre variables o sus potencias. A ese conjunto se le llama biblioteca de funciones.

Dados los datos observados en m instantes de tiempo, se organizan en una matriz $\mathbf{X} \in \mathbb{R}^{m \times n}$ y en una matriz $\dot{\mathbf{X}} \in \mathbb{R}^{m \times n}$. La matriz $\mathbf{X}$ representa los estados de cada variable, y la matriz $\dot{\mathbf{X}}$ representa sus derivadas. Cada fila de estas matrices corresponde a un instante de tiempo, y cada columna a una variable de estado distinta. De esta forma, toda la información observada queda resumida en una estructura ordenada, lista para ser usada por el método.

A partir de $\mathbf{X}$ se construye la matriz de evaluación $\Theta(\mathbf{X}) \in \mathbb{R}^{m \times p}$, cuyas columnas representan la evaluación de los términos candidatos de la biblioteca, como 1 , x_i , $x_i x_j$, x_i^2 , etc. En otras palabras, la biblioteca es el catálogo de funciones posibles y $\Theta(\mathbf{X})$ es la versión numérica de ese catálogo aplicada a los datos. El modelo se escribe entonces como

$$\dot{\mathbf{X}} = \Theta(\mathbf{X}) \Xi,$$

donde $\Xi \in \mathbb{R}^{p \times n}$ es la matriz de coeficientes. Esta formulación permite estimar Ξ resolviendo un problema con una función objetivo convexa en el que cualquier

mínimo local coincide con el mínimo global [51]. El objetivo es obtener una solución dispersa: la mayoría de los coeficientes en Ξ son cero, de modo que solo unos pocos términos de la biblioteca contribuyan al modelo. Para ello se aplica regularización ℓ_1 , una penalización sobre la suma de valores absolutos de los coeficientes, como LASSO [52].

SINDy ha demostrado su eficacia en la identificación de sistemas clásicos como las ecuaciones de Lorenz, el oscilador de Duffing y modelos de fluidos [50], así como en la identificación de ecuaciones en derivadas parciales [53]. La implementación de referencia está disponible en el paquete PySINDy [54].

En síntesis, SINDy ofrece otra vía para identificar dinámicas a partir de datos, siempre que la estructura real del sistema pueda expresarse con la biblioteca elegida. Su limitación es, precisamente, esa dependencia: si el modelo verdadero contiene términos fuera de dicha biblioteca, el método no puede recuperarlos [50].

En este capítulo se han introducido los conceptos teóricos sobre los que se construye el resto del trabajo: las ecuaciones diferenciales ordinarias como herramienta para la modelación dinámica, los sistemas compartimentales como familia particular relevante en epidemiología, y el problema de la regresión simbólica para la identificación automática de modelos a partir de datos. También se han revisado enfoques metodológicos para abordar este problema.

El capítulo siguiente desarrolla con detalle los dos enfoques utilizados en esta tesis y propone un método híbrido que combina las fortalezas de cada uno.

Capítulo 2

Metodología

Este capítulo describe los dos enfoques metodológicos utilizados en este trabajo para identificar automáticamente sistemas de ecuaciones diferenciales que describen dinámicas compartimentales a partir de datos observados. En primer lugar, se presenta la regresión simbólica basada en algoritmos genéticos, que explora directamente el espacio de expresiones matemáticas y garantiza la estructura compartimental mediante una representación por flujos. En segundo lugar, se introduce SINDy, un método de identificación dispersa que formula el problema como una regresión lineal regularizada sobre una biblioteca de funciones candidatas.

La exposición se organiza en dos bloques. El primero desarrolla el enfoque evolutivo: el problema de regresión simbólica, la representación de individuos, la función de aptitud, los operadores genéticos y el ciclo evolutivo completo. El segundo presenta SINDy, sus fundamentos, sus ventajas prácticas frente al enfoque evolutivo y un experimento ilustrativo con el modelo SIR.

2.1. Algoritmo Genético para Regresión Simbólica de Sistemas Compartimentales

Este capítulo presenta la metodología basada en algoritmos genéticos para identificar sistemas de ecuaciones diferenciales compartimentales a partir de datos observados. El enfoque se basa en trabajos previos [49, 55] sobre regresión simbólica mediante algoritmos genéticos.

El capítulo está organizado de la siguiente manera: la Sección 2.1.1 introduce la representación de sistemas mediante árboles de expresión y la adaptación para garantizar linealidad respecto a los parámetros; la Sección 2.1.2 describe la representación de sistemas compartimentales mediante grafos dirigidos y cómo construir el sistema de ecuaciones a partir de ellos; la Sección 2.1.3 presenta la búsqueda de expresiones

para las aristas del grafo en lugar de para las ecuaciones del sistema; la Sección 2.1.4 define la función de costo que incluye la estimación de parámetros con restricciones de igualdad; finalmente, la Sección 2.1.5 describe los operadores genéticos y el ciclo evolutivo completo del algoritmo.

2.1.1. Representación de sistemas mediante árboles de expresión

Dado un conjunto de datos de la forma

$$\mathcal{D} = \{(t_j, y_i(t_j)) : i = 1, \dots, n, j = 1, \dots, m\}, \quad t_j \in \mathbb{R}, y_i(t_j) \in \mathbb{R}, \quad (2.1)$$

el objetivo de la regresión simbólica es encontrar un sistema de ecuaciones diferenciales

$$\frac{dy_i}{dt} = f_i(y_1, \dots, y_n), \quad i = 1, \dots, n, \quad (2.2)$$

que describa la dinámica observada en los datos. Nótese que los sistemas considerados en este trabajo son autónomos, es decir, las funciones f_i no dependen explícitamente del tiempo t .

Si se busca un sistema con n ecuaciones diferenciales, una forma de representar las soluciones candidatas es mediante una lista de n elementos, donde el elemento en la posición i representa la función $f_i(y_1, \dots, y_n)$. Por ejemplo, el modelo SIR

$$\frac{dS}{dt} = -\beta SI, \quad (2.3)$$

$$\frac{dI}{dt} = \beta SI - \gamma I, \quad (2.4)$$

$$\frac{dR}{dt} = \gamma I, \quad (2.5)$$

se puede representar mediante la lista

$$[-\beta SI, \beta SI - \gamma I, \gamma I]. \quad (2.6)$$

Siguiendo el enfoque de la programación genética [29], estas expresiones aritméticas se representan mediante *árboles de expresión* o árboles computacionales, donde los nodos interiores son operadores aritméticos (suma, resta, producto, cociente, negación) y los nodos hoja son variables o parámetros. La lista que representa el sistema se convierte entonces en una lista de árboles, donde cada árbol codifica la parte derecha de una ecuación.

Modificación para garantizar linealidad respecto a los parámetros

La mayoría de los modelos epidemiológicos reportados en la literatura, como SIR [56], SIRD, SEIRD y muchos otros, son sistemas lineales respecto a los parámetros. Un sistema es lineal respecto a los parámetros si cada ecuación tiene la forma

$$\frac{dy_i}{dt} = \sum_{k=1}^{p_i} a_{ik} g_{ik}(y_1, \dots, y_n), \quad (2.7)$$

donde los a_{ik} son los parámetros a estimar y cada función g_{ik} depende únicamente de las variables de estado pero *no* de los parámetros. Esta restricción, además de ser común en modelos epidemiológicos, tiene una ventaja computacional importante: la estimación de los parámetros óptimos para una estructura de árbol fija se reduce a resolver un sistema de ecuaciones lineales, sin necesidad de búsqueda iterativa.

Para garantizar esta estructura, se modifica la representación de árboles de Koza [29] de la siguiente manera:

1. La raíz de cada árbol que representa una ecuación es un nodo de suma especial que puede tener cualquier cantidad de hijos (sumandos).
2. Cada hijo de la raíz representa el producto $a_{ik} \cdot g_{ik}(y)$ y tiene exactamente dos hijos: un nodo hoja que contiene el parámetro a_{ik} y un subárbol que representa la función g_{ik} .
3. En el subárbol que representa g_{ik} , los nodos hoja solo pueden ser variables de estado, nunca parámetros.

La Figura 2.1 muestra la estructura general de un árbol que representa una ecuación lineal respecto a los parámetros, y la Figura 2.2 detalla la estructura de cada término individual.




Figura 2.1: Estructura de árbol que representa una ecuación diferencial lineal respecto a los parámetros. La raíz es un nodo de suma que agrupa todos los términos de la ecuación.




Figura 2.2: Estructura de un término de la ecuación. Cada término es un producto de un parámetro (nodo hoja) por una función que solo depende de las variables de estado (subárbol derecho).

Un sistema de ecuaciones diferenciales completo se representa como un árbol en el que cada ecuación es un hijo. La Figura 2.3 muestra la representación del sistema SIR.




Figura 2.3: Representación en árbol del modelo SIR completo. El nodo raíz SYSTEM agrupa las tres ecuaciones, cada una descompuesta como suma de términos.

Con esta representación, el algoritmo genético buscará árboles que cumplan automáticamente la restricción de linealidad respecto a los parámetros. Sin embargo, esta representación por sí sola no garantiza que los sistemas resultantes sean compartimentales. Las siguientes secciones introducen las modificaciones necesarias para ello.

2.1.2. Representación de sistemas compartimentales mediante grafos

Un sistema compartimental se puede representar de forma natural mediante un grafo dirigido en el que cada nodo corresponde a un compartimento y cada arista (i, j) lleva asociada una expresión matemática k_{ij} que describe el flujo de individuos desde el compartimento i hacia el compartimento j . La Figura 2.4 muestra un ejemplo genérico con tres compartimentos.




Figura 2.4: Ejemplo de grafo dirigido que representa un sistema compartimental con tres compartimentos A , B y C . Las aristas (A, B) y (B, C) representan los flujos entre compartimentos.

A partir de la representación mediante grafo dirigido, el sistema de ecuaciones diferenciales se construye de la siguiente manera: a cada compartimento i se le asocia una variable $x_i(t)$ que representa la cantidad de individuos en ese compartimento al tiempo t , y a cada arista (i, j) se le asocia una expresión k_{ij} que representa el flujo de individuos del compartimento i al compartimento j .

Para cada compartimento i , la derivada temporal es la diferencia entre los flujos de entrada y los flujos de salida:

$$\frac{dx_i}{dt} = \sum_{j \in \text{in}(i)} k_{ji} - \sum_{j \in \text{out}(i)} k_{ij}, \quad (2.8)$$

donde $\text{in}(i)$ es el conjunto de compartimentos con aristas dirigidas hacia i y $\text{out}(i)$ es el conjunto de compartimentos hacia los que i tiene aristas salientes.

Como ejemplo, considérese el modelo SIR representado mediante el grafo de la Figura 2.5. El grafo tiene dos aristas: (S, I) con expresión $k_{SI} = \beta SI$ y (I, R) con expresión $k_{IR} = \gamma I$. Aplicando la ecuación (2.8) a cada compartimento se obtiene:

- Para S : no tiene aristas entrantes ($\text{in}(S) = \emptyset$), tiene una arista saliente (S, I) con flujo $k_{SI} = \beta SI$ ($\text{out}(S) = \{I\}$). Por tanto,

$$\frac{dS}{dt} = \sum_{j \in \emptyset} k_{jS} - \sum_{j \in \{I\}} k_{Sj} = 0 - \beta SI = -\beta SI.$$

- Para I : tiene una arista entrante (S, I) con flujo $k_{SI} = \beta SI$ ($\text{in}(I) = \{S\}$) y una arista saliente (I, R) con flujo $k_{IR} = \gamma I$ ($\text{out}(I) = \{R\}$). Por tanto,

$$\frac{dI}{dt} = \sum_{j \in \{S\}} k_{jI} - \sum_{j \in \{R\}} k_{Ij} = \beta SI - \gamma I.$$

- Para R : tiene una arista entrante (I, R) con flujo $k_{IR} = \gamma I$ ($\text{in}(R) = \{I\}$) y no tiene aristas salientes ($\text{out}(R) = \emptyset$). Por tanto,

$$\frac{dR}{dt} = \sum_{j \in \{I\}} k_{jR} - \sum_{j \in \emptyset} k_{Rj} = \gamma I - 0 = \gamma I.$$

Estas son precisamente las ecuaciones (2.3)–(2.5) del modelo SIR.




Figura 2.5: Grafo dirigido del modelo SIR. La arista $S \rightarrow I$ lleva la expresión $k_{SI} = \beta SI$ que representa el flujo de susceptibles que se infectan, y la arista $I \rightarrow R$ lleva la expresión $k_{IR} = \gamma I$ que representa el flujo de infectados que se recuperan.

Con esta representación mediante grafos, el problema de encontrar el sistema de ecuaciones diferenciales que mejor ajuste un conjunto de datos se puede reformular como el problema de encontrar las expresiones k_{ij} asociadas a las aristas del grafo. Una vez encontradas estas expresiones, el sistema completo se construye aplicando la ecuación (2.8).

2.1.3. Modificación de árboles: búsqueda sobre aristas

La representación de árboles descrita en la Sección 2.1.1 busca un árbol de expresión por cada ecuación del sistema, digamos n árboles. Sin embargo, como se explicó en la sección anterior, un sistema compartimental se define completamente por las expresiones asociadas a las m aristas de su grafo dirigido.

El enfoque adoptado consiste en cambiar el objeto de búsqueda: en lugar de buscar n árboles, el algoritmo genético busca un árbol por arista, digamos m árboles. A partir de estos m árboles, el sistema de n ecuaciones se reconstruye aplicando la ecuación (2.8).

Este enfoque tiene dos consecuencias fundamentales:

1. Garantía de compartimentalidad: El sistema reconstruido es compartimental por construcción. Los flujos de entrada y salida de cada compartimento provienen de las mismas expresiones, por lo que la estructura del grafo se respeta automáticamente. En particular, esto garantiza que se cumple la propiedad de conservación: la suma de todas las derivadas es igual a la suma de las fuentes externas.
2. Igualdad de parámetros: Los parámetros que aparecen en la misma arista tienen el mismo valor en todas las ecuaciones donde ese flujo interviene. Por ejemplo, en el modelo SIR, el parámetro β de la arista (S, I) aparece con signo negativo en la ecuación de S y con signo positivo en la ecuación de I , pero es el mismo parámetro β . Esta igualdad se debe garantizar durante la estimación de parámetros, como se explica en la Sección 2.1.4.

Las Figuras 2.6 y 2.7 comparan las dos representaciones para el modelo SIR. En el árbol original (Figura 2.6) la raíz tiene tres hijos, uno por cada ecuación. En el árbol alternativo (Figura 2.7) la raíz tiene dos hijos, uno por cada arista del grafo. Las tres ecuaciones del sistema se reconstruyen a partir de estos dos subárboles aplicando la ecuación (2.8): el primer subárbol (βSI) aparece con signo negativo en la ecuación de S y con signo positivo en la ecuación de I ; el segundo subárbol (γI) aparece con signo negativo en la ecuación de I y con signo positivo en la ecuación de R .




Figura 2.6: Representación en árbol original del modelo SIR: un hijo por ecuación. La raíz tiene tres subárboles correspondientes a las tres ecuaciones del sistema.




Figura 2.7: Representación en árbol alternativa del modelo SIR: un hijo por arista. La raíz tiene dos subárboles correspondientes a las dos aristas del grafo. Esta representación reduce los árboles buscados de tres a dos y garantiza por construcción que el sistema resultante sea compartimental.

Esta representación por aristas aprovecha los métodos de regresión simbólica [55] garantizando simultáneamente que los sistemas resultantes sean compartimentales. El único requisito es que el grafo dirigido del sistema sea conocido de antemano.

2.1.4. Función de costo y estimación de parámetros

Una vez que se tiene un sistema candidato representado como árbol de expresión, es necesario evaluar qué tan bien describe los datos observados. Para ello, se define una función de costo que mide la discrepancia entre las derivadas predichas por el sistema y las derivadas aproximadas a partir de los datos.

Aproximación de derivadas

Dado el conjunto de datos $\mathcal{D} = \{(t_j, y_i(t_j)) : i = 1, \dots, n, j = 1, \dots, m\}$, se aproximan las derivadas $y'_i(t_j)$ de las funciones desconocidas en cada instante t_j . Si los datos no contienen ruido, se pueden utilizar diferencias finitas [39]; en presencia de ruido, se utiliza un *spline* de suavizado cúbico para aproximar las funciones y_i y luego se calcula la derivada del *spline*.

De esta manera, se genera un conjunto de datos aumentado:

$$\mathcal{D}' = \{(t_j, y_i(t_j), y'_i(t_j)) : i = 1, \dots, n, j = 1, \dots, m\}, \quad (2.9)$$

donde $y'_i(t_j)$ es la aproximación de la derivada de la función y_i en el instante t_j .

Función de costo

Para un sistema candidato f con parámetros $a = (a_1, \dots, a_K)$, la función de costo se define como:

$$C(f, a) = \frac{1}{n} \sum_{i=1}^n \frac{1}{m} \sum_{j=1}^m \left(y'_i(t_j) - f_i(y(t_j), a) \right)^2 + P(f), \quad (2.10)$$

donde $f_i(y(t_j), a)$ es la predicción del sistema para la derivada de y_i en el instante t_j y $P(f)$ es un término de penalización por complejidad definido como:

$$P(f) = \begin{cases} \lambda \cdot \text{node_count}(f), & \text{si } \text{node_count}(f) \geq \text{MAX_NODES}, \\ 0, & \text{en otro caso,} \end{cases} \quad (2.11)$$

donde $\text{node_count}(f)$ es el número de nodos en la representación en árbol del sistema, λ es una constante de penalización y MAX_NODES es un umbral. Este término penaliza sistemas excesivamente complejos, favoreciendo soluciones más simples cuando el ajuste es comparable.

Estimación de parámetros con restricciones de igualdad

Como se explicó en la Sección 2.1.1, los sistemas buscados son lineales respecto a los parámetros. Esto implica que cada función f_i tiene la forma

$$f_i(y(t_j), a) = \sum_{k=1}^{p_i} a_{ik} g_{ik}(y(t_j)), \quad (2.12)$$

donde los a_{ik} son los parámetros, y las g_{ik} son funciones que solo dependen de las variables de estado.

Para minimizar la función de costo (2.10), se deben encontrar los valores de los parámetros que minimicen el error cuadrático. Sin embargo, como se explicó en la Sección 2.1.3, los parámetros que corresponden a la misma arista del grafo deben tener el mismo valor. Esto introduce restricciones de igualdad en el problema de optimización.

Siguiendo la metodología propuesta por Valdés et al. [57], se utiliza el método de multiplicadores de Lagrange y las condiciones de Karush-Kuhn-Tucker (KKT) para resolver el problema de minimización con restricciones de igualdad. El problema se formula como:

$$\min_a \sum_{i=1}^n \sum_{j=1}^m \left(y'_i(t_j) - f_i(y(t_j), a) \right)^2 \quad (2.13)$$

sujeto a $a_{ik} = a_{jl}$ para pares de parámetros que deben ser iguales,

donde los pares (a_{ik}, a_{jl}) son aquellos que corresponden a la misma arista del grafo.

La estrategia consiste en reescribir inicialmente el sistema considerando todos los parámetros como distintos, lo que permite expresar el problema como un sistema de mínimos cuadrados estándar, y luego incorporar las restricciones de igualdad mediante las condiciones de KKT. Como el sistema es lineal respecto a los parámetros, las condiciones de KKT dan lugar a un sistema de ecuaciones lineales de la forma

$$\begin{pmatrix} A & B^T \\ B & 0 \end{pmatrix} \begin{pmatrix} a \\ \lambda \end{pmatrix} = \begin{pmatrix} b \\ 0 \end{pmatrix}, \quad (2.14)$$

donde a es el vector de parámetros, λ es el vector de multiplicadores de Lagrange, A es la matriz del sistema de mínimos cuadrados sin restricciones, B codifica las restricciones de igualdad, y b es el vector de términos independientes. Una vez resuelto este sistema, se obtienen los valores óptimos de los parámetros (los multiplicadores λ se descartan).

A modo de ejemplo, considérese el modelo SIR. Reescribiendo el sistema con todos los parámetros distintos se tiene:

$$\frac{dS}{dt} = -\alpha_1 SI, \quad (2.15)$$

$$\frac{dI}{dt} = \alpha_2 SI - \alpha_3 I, \quad (2.16)$$

$$\frac{dR}{dt} = \alpha_4 I, \quad (2.17)$$

con las restricciones $\alpha_1 = \alpha_2$ (ambos corresponden a la arista (S, I)) y $\alpha_3 = \alpha_4$ (ambos corresponden a la arista (I, R)). El sistema KKT resultante es de tamaño 6×6 e incluye los cuatro parámetros $\alpha_1, \alpha_2, \alpha_3, \alpha_4$ y dos multiplicadores de Lagrange λ_1, λ_2 . Después de resolver el sistema, se obtienen los valores óptimos de α_1 y α_3 , que corresponden a los parámetros β y γ del modelo original.

2.1.5. Operadores genéticos y ciclo evolutivo

El algoritmo genético es una metaheurística inspirada en la evolución biológica que permite explorar el espacio de sistemas candidatos mediante tres operadores fundamentales: mutación, cruzamiento y selección. Dada una población inicial de N individuos (sistemas candidatos), estos son sometidos a operaciones de mutación y cruzamiento para generar nuevos individuos. Del conjunto total de individuos, se seleccionan los mejores según la función de costo de la Sección 2.1.4. Este proceso se repite iterativamente hasta encontrar una solución suficientemente buena o hasta alcanzar un número máximo de generaciones.

Mutación

La mutación modifica un individuo existente para generar uno nuevo mediante cambios aleatorios en su estructura de árbol. Las operaciones de mutación incluyen: (1) eliminar un término completo de una expresión, (2) añadir un nuevo término con parámetro y función aleatorios, (3) cambiar una operación aritmética por otra (por ejemplo, suma por producto), (4) eliminar un nodo de operación reemplazándolo por uno de sus hijos, (5) sustituir una variable por otra, y (6) expandir una variable a una expresión más compleja. Estas operaciones permiten explorar el espacio de búsqueda modificando tanto la complejidad como la forma de las expresiones.

Cruzamiento

El cruzamiento combina dos individuos existentes para generar uno nuevo. Dados dos sistemas A y B , el operador selecciona un subárbol de cada uno y los intercambia, respetando siempre la estructura de linealidad respecto a los parámetros. Para garantizar que el resultado sea válido, el intercambio se realiza únicamente entre nodos del mismo nivel estructural: expresiones completas de aristas, términos individuales, u operaciones y variables dentro de un término. Esto asegura que el sistema resultante mantenga la correspondencia con las aristas del grafo compartimental.

Selección y ciclo evolutivo

A partir de una población de N individuos, se aplican los operadores de mutación y cruzamiento a subconjuntos seleccionados aleatoriamente, generando nuevos individuos que se agregan a la población. De la población expandida se seleccionan los N individuos que formarán la siguiente generación: los M mejores según la función de costo y $N - M$ individuos aleatorios para mantener diversidad genética. Este ciclo se repite hasta alcanzar un número máximo de generaciones o hasta encontrar una solución con costo inferior a un umbral predefinido. Al finalizar, el algoritmo retorna el mejor individuo encontrado.

2.2. SINDy: Identificación Dispersa de Dinámicas No Lineales

Esta sección presenta otra estrategia de solución al mismo problema: SINDy (*Sparse Identification of Nonlinear Dynamics*), un método determinista de identificación de sistemas dinámicos propuesto por Brunton, Proctor y Kutz [50] e implementado en la biblioteca de código abierto PYSINDY [54].

A diferencia del enfoque evolutivo, SINDy parte de la hipótesis de que las ecuaciones del sistema pueden expresarse como una combinación dispersa de un catálogo predefinido de funciones candidatas. Esta restricción transforma el problema de identificación en la búsqueda de coeficientes que minimicen el error de ajuste mientras se penaliza la complejidad, promoviendo soluciones con pocos términos activos o una combinación dispersa de términos. Este problema es conocido como regresión lineal regularizada [50, 58].

La sección está organizada de la siguiente manera: la Sección 2.3 describe los fundamentos del método SINDy y su estrategia de identificación dispersa; la Sección 2.4 analiza sus ventajas prácticas frente al enfoque evolutivo; la Sección 2.5 presenta su aplicación al modelo SIR clásico y discute los resultados obtenidos; finalmente, la Sección 2.6 identifica las limitaciones estructurales del método en el contexto de sistemas compartimentales y motiva el desarrollo del enfoque híbrido que se presentará en el siguiente capítulo.

2.3. Fundamentos de SINDy

La estrategia de SINDy se articula en torno a dos elementos: la biblioteca de funciones y el principio de esparcidad.

2.3.1. La biblioteca de funciones

SINDy requiere definir previamente el espacio de búsqueda: el conjunto de términos matemáticos entre los cuales el algoritmo seleccionará aquellos que mejor describan la dinámica observada. Este conjunto se denomina biblioteca de funciones o diccionario.

Para un sistema con n variables de estado $y_1, \dots, y_n$ se construye un catálogo que contiene todas las funciones candidatas de interés: términos que potencialmente podrían aparecer en las ecuaciones diferenciales del sistema.

En este ejemplo se emplea la biblioteca polinomial de grado d , que incluye todos los productos de hasta d variables. Para grado $d = 2$, esto comprende: el término constante 1, los términos lineales $(y_1, y_2, \dots, y_n)$, y todos los productos de dos variables $(y_1 y_2, y_1 y_3, y_1^2, \dots, y_n^2)$.

En el experimento con el modelo SIR, con $n = 3$ variables S, I, R , y biblioteca de grado 2, el catálogo contiene diez términos:

$$\mathcal{B} = \{1, S, I, R, S^2, SI, SR, I^2, IR, R^2\}. \quad (2.18)$$

Cada ecuación del sistema se expresa como combinación lineal de estos términos:

$$\dot{y}_i \approx \xi_{i0} \cdot 1 + \xi_{i1} \cdot S + \xi_{i2} \cdot I + \dots + \xi_{i9} \cdot R^2. \quad (2.19)$$

2.3.2. El principio de esparcidad

SINDy parte del supuesto de que, aunque la biblioteca contiene varios términos candidatos, no todos contribuyen realmente a la dinámica del sistema. Esta hipótesis, conocida como *esparcidad*, es razonable para modelos teóricos simples como el SIR: el sistema de ecuaciones contiene solo 2 términos repartidos en sus 3 ecuaciones, ($\pm\beta SI$ y $\pm\gamma I$), frente a todos los posibles que ofrece la biblioteca de grado 2.

Para garantizar que la solución identificada tenga pocos términos activos, SINDy impone que solo unos pocos coeficientes ξ_{ij} sean distintos de cero. Para ello emplea el optimizador STLSQ (*Sequential Thresholded Least Squares*) [50, 52]: en cada iteración se resuelve un problema de mínimos cuadrados y se eliminan los coeficientes cuyo módulo cae por debajo de un umbral λ_s . Este proceso se repite hasta que se alcance algún criterio de convergencia.

El problema de optimización que resuelve SINDy consiste en encontrar los coeficientes ξ que minimicen el error cuadrático:

$$\min_{\xi} \sum_{k=1}^m \left(\dot{X}_k - [\Theta\xi]_k \right)^2, \quad (2.20)$$

donde m es el número de puntos temporales. Aquí, $\dot{X}$ es un vector que contiene las derivadas temporales $\dot{y}_i(t_k)$ estimadas numéricamente a partir de las series temporales observadas en cada instante t_k ; Θ es la matriz de la biblioteca, cuya fila k -ésima contiene los valores de todas las funciones candidatas evaluadas en el punto temporal t_k ; y ξ es el vector de coeficientes buscados que determina qué términos de la biblioteca participan en la ecuación identificada. El resultado es un sistema de ecuaciones con pocos términos activos que reproduce las derivadas observadas y, al integrarse, reconstruye la evolución temporal de las variables de estado.

2.4. Ventajas frente al enfoque evolutivo

Frente a la regresión simbólica mediante algoritmos genéticos [47, 48], SINDy presenta cuatro ventajas prácticas importantes:

1. **Velocidad.** El tiempo de ejecución oscila entre fracciones de segundo y pocos segundos, independientemente del tamaño del sistema. El algoritmo genético, en cambio, puede requerir minutos u horas para converger sobre sistemas de complejidad equivalente.
2. **Determinismo.** SINDy no contiene componentes estocásticos: dada la misma entrada, produce siempre el mismo resultado. El algoritmo genético parte de una población aleatoria y emplea operadores de variación estocástica, por lo que requiere múltiples ejecuciones independientes para obtener resultados robustos.

3. **Coeficientes directamente interpretables.** Los coeficientes ξ_{ij} tienen una interpretación inmediata como tasas o constantes del proceso modelado. Cuando SINDy identifica correctamente el término βSI , el coeficiente estimado es directamente comparable con la tasa de transmisión β del modelo teórico.
4. **Pocos hiperparámetros.** SINDy requiere configurar únicamente el grado de la biblioteca y el umbral de dispersión λ_s . El algoritmo genético requiere ajustar tamaño de población, número de generaciones, tasas de mutación y cruzamiento, parámetros de penalización de complejidad, etc.

2.5. Aplicación al modelo SIR: resultados y análisis

Como ejemplo de aplicación de SINDy a sistemas epidemiológicos, se aplica al modelo SIR clásico de Kermack y McKendrick [56]. El experimento consiste en generar datos sintéticos a partir de las ecuaciones conocidas del modelo, para luego aplicar SINDy sobre esos datos y verificar si el método es capaz de recuperar las ecuaciones originales.


El modelo SIR clásico describe la dinámica mediante las ecuaciones:

$$\begin{aligned}\dot{S} &= -\beta SI, \\ \dot{I} &= \beta SI - \gamma I, \\ \dot{R} &= \gamma I,\end{aligned}\tag{2.21}$$

donde β representa la tasa de transmisión y γ la tasa de recuperación.

Para realizar el experimento, se eligen los valores $\beta = 0.3$ y $\gamma = 0.1$, condición inicial $(S_0, I_0, R_0) = (0.7, 0.3, 0)$, y se integra el sistema en 300 puntos temporales uniformes en el intervalo $[0, 20]$ sin añadir ruido. Esta integración numérica produce las series temporales $S(t)$, $I(t)$, $R(t)$ que se usan como entrada de SINDy, configurado con biblioteca polinomial de grado 2 y umbral de dispersión $\lambda_s = 0.01$. Esto significa que las funciones candidatas son todas estas, y que si al resolver el problema de mínimos cuadrados, algún coeficiente es menor que 0.01, se elimina y se repite el proceso.

La Figura 2.8 muestra la trayectoria original del sistema (izquierda) y la solución integrada a partir del sistema encontrado por SINDy (derecha).



Trayectoria original.

Solución SINDy integrada vs. datos originales.

Figura 2.8: Modelo SIR: datos de entrenamiento y ajuste de SINDy. La solución integrada a partir del sistema identificado reproduce fielmente la trayectoria observada.

Las ecuaciones identificadas por SINDy son:

$$\begin{aligned} \dot{S} \approx & -0.0333 - 0.0340S - 0.0328I + 0.0334R \\ & + 0.0670S^2 - 0.1659SI + 0.0649SR + 0.0667I^2 + 0.0664IR, \end{aligned} \quad (2.22)$$

$$\dot{I} \approx 0.0003S - 0.1006I + 0.0019R + 0.2997SI - 0.0017IR - 0.0020R^2, \quad (2.23)$$

$$\dot{R} \approx 0.1001I. \quad (2.24)$$

Analizando los resultados en relación con el sistema verdadero (2.21):

- La ecuación de R (3.11) es virtualmente exacta: $0.1001I \approx \gamma I$.
- La ecuación de I (3.10) recupera los dos términos dominantes: $0.2997SI \approx \beta SI$ y $-0.1006I \approx -\gamma I$. Los cuatro términos adicionales presentan coeficientes del orden de 10^{-3} , dos órdenes de magnitud menores que los dominantes, y no corresponden a ningún mecanismo epidemiológico.
- La ecuación de S (3.9) es la más problemática: aparecen nueve términos con coeficientes de magnitud comparable. El coeficiente del término SI es solo -0.1659 , en lugar del valor verdadero $-\beta = -0.3$.

Estos resultados revelan que aunque el sistema identificado ajusta perfectamente los datos de entrenamiento, la estructura recuperada no coincide con el modelo que generó esos datos. Además, el sistema no conserva el flujo entre compartimentos: si se suman las tres ecuaciones identificadas, el resultado no es cero como exige la conservación de población, sino una combinación de términos adicionales que se cancelan solo sobre la trayectoria de entrenamiento.

A pesar de estas limitaciones, SINDy identifica correctamente varios de los términos dominantes: la ecuación de $\dot{R}$ es virtualmente exacta y la de $\dot{I}$ recupera ambos términos principales con alta precisión. Esta capacidad de localizar la estructura aproximada del sistema en fracciones de segundo lo convierte en un candidato ideal para inicializar el algoritmo genético: en lugar de comenzar con una población completamente aleatoria, el método híbrido puede partir de una solución que ya captura gran parte de la dinámica, permitiendo al AG refinarla y corregir las inconsistencias estructurales.

2.6. Limitaciones estructurales de SINDy

SINDy constituye un método de identificación rápido, determinista y matemáticamente bien fundado. En condiciones favorables como lo son datos sin ruido, dinámica polinomial y ausencia de leyes de conservación activas, los términos dominantes se recuperan con gran precisión en tiempos de cómputo del orden de milisegundos [50]. Estas cualidades lo hacen valioso como herramienta de exploración inicial.

No obstante, el experimento realizado muestra que SINDy no produce modelos epidemiológicamente interpretables de manera consistente. El modelo ajusta los datos pero no recupera la estructura que los generó.

Estas limitaciones son precisamente fortalezas del enfoque evolutivo presentado anteriormente: el algoritmo genético no asume ninguna forma funcional predefinida, opera sobre el espacio completo de expresiones representables y puede encontrar, en principio, la estructura exacta del modelo. Su debilidad es la eficiencia: parte de una población aleatoria y requiere muchas generaciones para localizar regiones prometedoras del espacio de búsqueda.

Esta complementariedad motiva el método híbrido GA+SINDy que se presenta en el próximo capítulo.

Capítulo 3

Propuesta

Los capítulos anteriores presentaron dos enfoques para la identificación de sistemas dinámicos compartimentales: el algoritmo genético, que explora el espacio completo de expresiones simbólicas mediante operadores evolutivos, y SINDy, que ajusta coeficientes dispersos sobre una biblioteca predefinida. Ambos métodos tienen ventajas y limitaciones.

El algoritmo genético no asume ninguna forma funcional previa y puede descubrir estructuras arbitrarias, pero parte de una población aleatoria y requiere muchas generaciones para converger hacia soluciones de buena calidad.

SINDy produce una respuesta en fracciones de segundo e identifica los términos dominantes del sistema, pero está limitado a combinaciones lineales de la biblioteca y no garantiza la conservación de flujos entre compartimentos por lo que su solución no es compartimental.

El método híbrido GA+SINDy que se presenta en este capítulo combina ambas fortalezas mediante una estrategia de inicialización informada: en lugar de comenzar con una población completamente aleatoria, el algoritmo genético se inicializa con soluciones construidas a partir del ajuste SINDy. Esto permite al AG partir de una región prometedora del espacio de búsqueda y dedicar las generaciones disponibles a refinar y extender esa solución.

Las principales contribuciones de este capítulo son:

1. Enriquecimiento de características epidemiológicas: agregar al conjunto de hojas del AG los términos de incidencia frecuencia-dependiente, como SI/N , que representa la tasa de contacto entre susceptibles e infectados y donde N es la población total, y una constante para modelar flujos externos.
2. Manejo de flujos externos: representación de procesos como natalidad, inmigración o vacunación mediante flujos con origen externo.

3. Algoritmo de traducción: proceso para convertir las ecuaciones polinomiales dispersas de SINDy en árboles de expresión del AG, usando las características permitidas de cada flujo como filtro.
4. Población inicial híbrida: estrategia que combina copias de las ecuaciones encontradas por SINDy con individuos aleatorios para balancear explotación y exploración.

El capítulo está organizado de la siguiente manera: la sección 3.1 describe el enriquecimiento de características que amplía el espacio de expresiones del AG; la sección 3.2 detalla la representación de flujos externos; la sección 3.3 detalla el algoritmo de traducción de ecuaciones SINDy a árboles del AG; la sección 3.4 explica la composición de la población inicial híbrida; finalmente, la sección 3.5 resume el procedimiento completo.

A lo largo del capítulo se desarrolla un ejemplo único basado en el modelo SIRD con natalidad constante, que ilustra cada etapa del proceso.

3.1. Enriquecimiento de características

El algoritmo genético representa cada flujo del sistema como un árbol de expresión cuyas hojas son variables de estado o constantes numéricas. Para el modelo SIRD, las hojas disponibles en su versión base son S , I , R y D . El método híbrido extiende este conjunto con características adicionales derivadas de la estructura epidemiológica del problema.

Considérese el término de transmisión de la infección $\beta \cdot S \cdot I/N$ que aparece en muchos modelos epidemiológicos. Si el AG solo dispone de las variables S , I , R y N como hojas, debe construir este término mediante un árbol de tres niveles:

$$\text{DIV}\left(\text{MUL}\left(\beta, \text{MUL}(S, I)\right), N\right), \quad (3.1)$$

Esto aumenta el tamaño del árbol y dificulta que los operadores de mutación y cruce exploren eficientemente expresiones que incluyan el término SI/N .

Una de las estrategias adoptadas por el método híbrido consiste en pre-computar los términos de incidencia $X_i X_j/N$ para todos los pares de compartimentos y agregarlos como hojas atómicas. De esta forma, el término $\beta \cdot SI/N$ se representa simplemente como:

$$\text{MUL}\left(\beta, \text{leaf}("SI/N")\right), \quad (3.2)$$

reduciendo la profundidad del árbol y facilitando la búsqueda.

Para un modelo compartimental con variables de estado $\{X_1, \dots, X_n\}$, el método híbrido agrega las siguientes características:

1. Términos de incidencia cruzados: Para cada par de compartimentos distintos (i, j) con $i < j$, se pre-computa el producto cruzado $X_i X_j / N$. Esto incluye términos como SI/N , SR/N , IR/N .
2. Constante: Una característica con valor 1, que permite al AG representar términos constantes en las ecuaciones, por ejemplo, el término a en una expresión como $a - b \cdot SI$, donde a es una tasa de entrada externa independiente del estado del sistema.

Este enriquecimiento de características amplía el espacio de expresiones que el AG puede representar de manera eficiente, permitiendo capturar directamente términos epidemiológicamente relevantes sin necesidad de construirlos a partir de variables básicas.

En el ejemplo del modelo SIRD con natalidad, esto es crucial para que el AG pueda representar tanto la tasa de transmisión de la enfermedad $b \cdot SI/N$ como la tasa de natalidad constante a con árboles de expresión simples y modificables por los operadores evolutivos.

3.1.1. Ejemplo: modelo SIRD con natalidad

Sea el modelo SIRD:

$$\frac{dS}{dt} = a - b \frac{SI}{N}, \quad (3.3)$$

$$\frac{dI}{dt} = b \frac{SI}{N} - cI - dI, \quad (3.4)$$

$$\frac{dR}{dt} = cI, \quad (3.5)$$

$$\frac{dD}{dt} = dI, \quad (3.6)$$

En este ejemplo particular, se toma $a = 250$ como tasa de natalidad, $b = 0.5$ como tasa de transmisión, $c = 0.1$ como tasa de recuperación, y $d = 0.2$ como tasa de mortalidad por la enfermedad. La población total $N = S + I + R + D$ varía con el tiempo.

Para este ejemplo, las variables de estado originales del modelo son $\{S, I, R, D\}$, y el método híbrido agrega las siguientes características:

- Términos cruzados de incidencia: SI/N , SR/N , SD/N , IR/N , ID/N , RD/N , y el término constante: 1.

Este conjunto enriquecido permite al AG representar directamente el término de transmisión $b \cdot SI/N$ y el término de natalidad constante $a \cdot 1$ con árboles de profundidad 1.

Una vez presentado el conjunto enriquecido de características, la siguiente sección aborda un tipo particular de flujo: aquellos que incorporan individuos al sistema desde el exterior.

3.2. Flujos externos

Los modelos epidemiológicos pueden incluir procesos que incorporan o extraen individuos del sistema sin que provengan de otro compartimento interno. Ejemplos típicos son la natalidad y la inmigración. En este trabajo se propone una extensión de la representación por flujos del AG para modelar explícitamente estos procesos externos.

En la formulación estándar del AG para sistemas compartimentales, cada flujo se define mediante un par (src, dst) que indica el compartimento de origen y el de destino, donde ambos deben ser compartimentos internos del modelo. Esto imposibilitaba representar procesos externos como natalidad o inmigración. La contribución de este trabajo consiste en relajar esta restricción, permitiendo que el origen o el destino sea *None*, indicando que los individuos provienen de fuera del sistema o que salen del sistema.

La Figura 3.1 ilustra esta extensión con el modelo SIRD con natalidad.

Sin la capacidad de representar flujos externos, el modelo solo puede capturar las tres transiciones internas (transmisión, recuperación, mortalidad), resultando imposible modelar el término de natalidad ($+a$) en la ecuación (3.3).

Con la extensión propuesta, el flujo externo $(None, S)$ permite incorporar este proceso, donde la tasa del flujo se determina mediante la expresión asociada que depende de la constante “1”.




Figura 3.1: Comparación de representaciones del modelo SIRD con natalidad. (a) La formulación estándar solo permite flujos entre compartimentos internos, haciendo imposible capturar el término de natalidad constante. (b) La nueva contribución permite flujos externos mediante $\text{src} = \text{None}$ (arista discontinua azul), representando procesos que incorporan individuos desde fuera del sistema. Los cuatro flujos del modelo son: f_0 (transmisión $S \rightarrow I$), f_1 (recuperación $I \rightarrow R$), f_2 (mortalidad $I \rightarrow D$), y f_3 (natalidad $\text{None} \rightarrow S$).

El método híbrido permite especificar qué características puede usar cada flujo externo según las necesidades del modelo. Para procesos como natalidad o inmigración, cuyas tasas no dependen necesariamente de las variables de estado del sistema, se restringe el flujo a la constante “1”. Para otros procesos externos que sí dependen del estado actual, como una tasa de vacunación proporcional a la población susceptible, el método permite incluir las variables relevantes en las características permitidas del flujo.

Las dos secciones anteriores establecieron las extensiones estructurales del método híbrido: el enriquecimiento de características y la capacidad de modelar flujos externos. Con estas piezas en su lugar, la siguiente sección describe el algoritmo que traduce las ecuaciones dispersas de SINDy en árboles de expresión del AG.

3.3. Traducción de ecuaciones SINDy a flujos del AG

El proceso de traducción del método híbrido convierte las ecuaciones dispersas producidas por SINDy en árboles de expresión compatibles con la representación de flujos del algoritmo genético. Esta sección describe el algoritmo de traducción y lo ilustra con el modelo SIRD.

SINDy ajusta un modelo de la forma

$$\frac{dX_i}{dt} = \sum_j \xi_{ij} \varphi_j(\mathbf{X}), \quad (3.7)$$

donde X_i son las variables de estado, $\varphi_j(\mathbf{X})$ son funciones de la biblioteca, y ξ_{ij} son los coeficientes identificados. El resultado es un sistema de n ecuaciones, una por cada variable de estado.

Por otro lado, el algoritmo genético representa el sistema mediante m flujos indexados por $k = 1, \dots, m$.

Cada flujo k se define por un origen src_k , un destino dst_k y una tasa escalar $e_k(\mathbf{X})$, que puede ser constante o depender de las variables de estado $\mathbf{X}$. La dinámica de cada compartimento X_i se reconstruye sumando los flujos que entran y restando los que salen:

$$\frac{dX_i}{dt} = \sum_{k:dst_k=i} e_k(\mathbf{X}) - \sum_{k:src_k=i} e_k(\mathbf{X}), \quad (3.8)$$

donde $\sum_{k:dst_k=i}$ recorre los flujos cuyo destino es X_i , y $\sum_{k:src_k=i}$ recorre los flujos cuyo origen es X_i .

La traducción consiste en extraer de las n ecuaciones identificadas por SINDy las expresiones correspondientes a los m flujos del AG, utilizando información epidemiológica previa sobre cada flujo, que fija qué variables son admisibles en su tasa.

Cada flujo del AG tiene un conjunto de características permitidas que especifica qué variables puede usar su expresión, aunque a falta de información a priori, se pueden usar todas las variables. En caso de que esté disponible, este conocimiento epidemiológico reduce el espacio de búsqueda del AG y facilita la interpretación del modelo identificado.

Para el modelo SIRD que se está desarrollando como ejemplo, las características permitidas en cada flujo son:

Flujo	Descripción	Características permitidas
$f_0 : S \rightarrow I$	Transmisión	$\{S, I, N, SI/N\}$
$f_1 : I \rightarrow R$	Recuperación	$\{I\}$
$f_2 : I \rightarrow D$	Mortalidad	$\{I\}$
$f_3 : \text{None} \rightarrow S$	Natalidad	$\{1\}$

La transmisión puede depender de susceptibles, infectados, la población total, o su incidencia; la recuperación y mortalidad dependen solo de infectados; y la natalidad, en este ejemplo, es una tasa constante.

Para construir la expresión de cada flujo a partir de las ecuaciones SINDy, el método híbrido aplica el siguiente procedimiento:

1. Extraer términos compatibles:

De las ecuaciones que devuelve SINDy, que provienen de los compartimentos involucrados en el flujo, se extraen todos los términos cuyas variables pertenezcan al conjunto de características permitidas del flujo. Esto produce una lista de términos $\{c_1\varphi_1, c_2\varphi_2, \dots\}$, donde cada c_i es el coeficiente SINDy y φ_i es una función de la biblioteca.

2. Seleccionar top- k términos: se priorizan los términos siguiendo la siguiente heurística:

- a) Términos con signo contrario: se conservan aquellos que aparecen en ambos compartimentos con la misma función ϕ_i y coeficientes de signo contrario, ya que constituyen una evidencia fuerte de un flujo compartimental consistente.
- b) Términos con función coincidente: si la misma función ϕ_i aparece en ambos compartimentos aunque con coeficientes distintos, se considera como candidata prioritaria.
- c) Términos dominantes: si un término aparece solo en uno de los compartimentos pero su magnitud es suficientemente grande, se conserva como última alternativa, pues es preferible retener una contribución dominante a descartarla por completo.

3. Construir árbol de expresión:

Los términos seleccionados se convierten a la representación de árbol del AG.

Con el procedimiento general ya definido, conviene mostrar su aplicación en un caso concreto. A continuación se presenta la traducción paso a paso para el modelo SIRD, de modo que se vea con claridad cómo se filtran, priorizan y transforman los términos de SINDy en árboles de expresión del AG.

3.3.1. Ejemplo: traducción del modelo SIRD

Para ilustrar el algoritmo de traducción, consideremos datos generados a partir del modelo SIRD presentado anteriormente. Sobre esos datos se ajusta SINDy para obtener un sistema disperso inicial, que luego se traduce a la representación por flujos del AG.

El ajuste SINDy produce las siguientes ecuaciones:

$$\begin{aligned} \frac{dS}{dt} \approx & 247.1 - 0.000051 S - 0.000034 I + 0.000013 R \\ & + 0.000023 S^2 - 0.00493 SI + 0.000019 I^2, \end{aligned} \quad (3.9)$$

$$\begin{aligned} \frac{dI}{dt} \approx & -0.026 + 0.000049 S + 0.000031 I \\ & + 0.00486 SI - 0.299 I, \end{aligned} \quad (3.10)$$

$$\frac{dR}{dt} \approx 0.003 + 0.099 I, \quad (3.11)$$

$$\frac{dD}{dt} \approx 0.006 + 0.201 I. \quad (3.12)$$

Obsérvese que SINDy identifica correctamente los términos dominantes: la natalidad (≈ 247) en dS/dt , la transmisión ($-0.00493 SI$ en dS/dt y $+0.00486 SI$ en dI/dt , que aproximan $\mp b \cdot SI/N$ con $N \approx 10000$), la recuperación ($0.099 I \approx c I$), y la mortalidad ($0.201 I \approx d I$). Sin embargo, también aparecen términos pequeños que pudieran estar asociados al ruido.

3.3.2. Traducción flujo por flujo

A continuación se aplica el algoritmo de filtrado y selección a cada uno de los cuatro flujos del modelo SIRD, priorizando la coherencia entre ecuaciones sobre la magnitud de los coeficientes. Para claridad, se detalla el proceso completo únicamente para el flujo de transmisión; los flujos restantes siguen el mismo procedimiento.

Flujo de Transmisión: $S \rightarrow I$, **características permitidas:** $\{S, I, N, SI/N\}$

1. Extraer términos compatibles de las ecuaciones de los compartimentos involucrados (S e I):

- De (3.9): $-0.000051 S$, $-0.000034 I$, $0.000023 S^2$, $-0.00493 SI$, $0.000019 I^2$
- De (3.10): $0.000049 S$, $0.000031 I$, $0.00486 SI$, $-0.299 I$

Todos estos términos usan solo variables en $\{S, I\}$ (subconjunto de las permitidas).

2. Seleccionar términos candidatos siguiendo la heurística anterior:

Primero se identifican todos los términos que aparecen en ambas ecuaciones con signos contrarios:

- SI : -0.00493 en dS/dt , $+0.00486$ en $dI/dt \rightarrow$ coeficiente representativo: 0.004895

- S : -0.000051 en dS/dt , $+0.000049$ en $dI/dt \rightarrow$ coeficiente representativo: 0.000050
- I : -0.000034 en dS/dt , $+0.000031$ en $dI/dt \rightarrow$ coeficiente representativo: 0.0000325

Se seleccionan los $k = 2$ términos de mayor magnitud representativa: SI y S .

3. Construir árbol:

Los términos seleccionados se combinan en una suma ponderada usando un único coeficiente por término:

$$f_0 = \text{ADD}\left(\text{MUL}(-0.004895, \text{leaf}(SI)), \text{MUL}(-0.000050, \text{leaf}(S))\right). \quad (3.13)$$

El resultado es una tasa inicial para el flujo de transmisión que combina tanto el término dominante SI/N (que captura la estructura epidemiológica principal) como el término lineal en S (que modela perturbaciones asociadas a la dinámica susceptible). Esta combinación permite al algoritmo genético partir de una expresión más flexible que solo SI , facilitando la búsqueda de refinamientos posteriores.

Después de repetir este proceso con los demás flujos se tienen las siguientes ecuaciones semilla, ya escritas con un único coeficiente representativo por familia de términos:

$$\begin{aligned} f_0 &= -0.004895 SI - 0.000050 S, \\ f_1 &= -0.299 I + 0.099 I, \\ f_2 &= -0.299 I + 0.201 I, \\ f_3 &= 247.1. \end{aligned}$$

Con este procedimiento se obtiene un sistema semilla expresado en la representación de flujos del AG, donde cada flujo cuenta con una expresión inicial informada por SINDy y consistente con sus restricciones estructurales. El paso siguiente es incorporar esta semilla al proceso evolutivo sin perder capacidad de exploración, definiendo una población inicial que combine individuos informados e individuos aleatorios.

3.4. Población inicial híbrida

Una vez se construye el sistema semilla a partir de las ecuaciones SINDy, el método híbrido lo incorpora a la población inicial del algoritmo genético junto con individuos generados aleatoriamente. Esta sección describe la composición de la población híbrida y su propósito.

3.4.1. Composición de la población

La población inicial de tamaño P se compone de dos grupos:

1. Copias del sistema semilla: Se generan w copias independientes del sistema construido a partir de SINDy. Aunque las copias son estructuralmente idénticas en la generación 0, los operadores de mutación del AG las diversifican a partir de la generación 1, explorando distintas variaciones en torno a la solución SINDy.
2. Individuos aleatorios: Los restantes $P - w$ individuos se generan mediante el procedimiento de inicialización estándar del AG, que construye árboles aleatorios respetando las características permitidas de cada flujo.

La proporción w/P determina el balance entre refinamiento de la solución SINDy, que se puede ver como explotación, y la búsqueda en regiones no visitadas del espacio, que se puede ver como exploración. En los experimentos de este trabajo se empleó un valor del 20%:

Modelo	P	w	w/P
SIRD	200	40	20%

Con $P = 200$ y $w = 40$, la población inicial se construye insertando 40 copias de este sistema semilla y completando los 160 individuos restantes con sistemas generados aleatoriamente.

3.4.2. Diversificación y evolución

Las w copias del sistema semilla, inicialmente idénticas, comienzan a evolucionar de manera distinta en la primera generación debido a la acción de los operadores de mutación. Cada copia puede sufrir modificaciones distintas: cambio de coeficientes, sustitución de variables, adición o eliminación de subárboles, etc. Esto genera una población diversificada que explora el entorno local de la solución SINDy.

Los individuos aleatorios, por su parte, exploran regiones del espacio de búsqueda no necesariamente próximas a la solución SINDy. Su presencia evita la convergencia prematura del AG hacia un óptimo local cercano a la inicialización.

A lo largo de las generaciones, el mecanismo de selección por aptitud debería favorecer tanto a las variantes mejoradas de la semilla como a los individuos aleatorios que encuentren soluciones competitivas. El resultado debería ser una población que equilibra la explotación de la información proporcionada por SINDy con la exploración de estructuras alternativas.

3.5. Algoritmo completo

El método híbrido extiende el AG base únicamente en las etapas de preprocesamiento y de inicialización. A partir de la generación 1, el AG opera exactamente igual que en su versión estándar, sin modificaciones en los operadores de evaluación, selección, cruce o mutación.

El Algoritmo 1 de la página 40 resume el procedimiento completo del método híbrido GA+SINDy.

Este capítulo presentó el método híbrido GA+SINDy, que combina la velocidad y orientación estructural de SINDy con la flexibilidad del algoritmo genético mediante una estrategia de inicialización informada.

El método híbrido hereda las ventajas de ambos enfoques: la rapidez de SINDy para producir una primera aproximación en fracciones de segundo, y la capacidad del AG para refinar, extender y eventualmente modificar esa aproximación cuando los datos así lo requieran.

El capítulo siguiente presenta su validación experimental, comparando su desempeño frente al algoritmo genético puro sobre los modelos SIR, SIRD y SIQRD con distintos niveles de ruido.

Algorithm 1 Método híbrido GA+SINDy

Require: Datos temporales $\{(t_k, X_k)\}_{k=1}^m$, estructura de flujos $\{(src_i, dst_i)\}_{i=1}^{n_{\text{flujos}}}$, características permitidas por flujo $\{\text{FEATURES}_i\}_{i=1}^{n_{\text{flujos}}}$, parámetros del AG (P, G) , parámetros SINDy (λ_s, d) , tamaño de semilla w , número de términos por flujo k

Ensure: Sistema de EDOs compartimental $\hat{f}$

```

1: // 1. Preprocesamiento y enriquecimiento
2: Suavizar datos con splines cúbicos  $\rightarrow \tilde{X}(t)$ , estimar  $\dot{\tilde{X}}(t)$ 
3: for cada punto temporal  $t_j$  do
4:    $N_j \leftarrow \sum_i \tilde{X}_{ij}$ 
5:   for cada par  $(a, b)$  con  $a < b$  do
6:     Agregar característica  $\tilde{X}_{aj} \cdot \tilde{X}_{bj} / N_j$ 
7:   end for
8:   Agregar característica constante 1
9: end for
10: // 2. Ajuste SINDy
11: Ajustar modelo SINDy sobre  $(\tilde{X}, \dot{\tilde{X}})$  con umbral  $\lambda_s$  y grado  $d$ 
12: Obtener coeficientes  $\{\xi_{ij}\}$  y biblioteca  $\{\varphi_j\}$ 
13: // 3. Traducción a flujos
14: sistema_semilla  $\leftarrow \{\}$ 
15: for cada flujo  $i = 1, \dots, n_{\text{flujos}}$  do
16:   términos  $\leftarrow \{\}$ 
17:   for cada ecuación SINDy  $\frac{dX_\ell}{dt} = \sum_j \xi_{\ell j} \varphi_j$  do
18:     for cada término  $\xi_{\ell j} \varphi_j$  con  $|\xi_{\ell j}| > \epsilon$  do
19:       if  $\varphi_j$  usa solo variables en  $\text{FEATURES}_i$  then
20:         Agregar  $(\xi_{\ell j}, \varphi_j)$  a términos
21:       end if
22:     end for
23:   end for
24:   if términos  $\neq \emptyset$  then
25:     Ordenar términos por  $|\xi|$  descendente
26:     Seleccionar top- $k$  términos
27:     Construir árbol de expresión  $e_i$  combinando términos
28:   else
29:      $e_i \leftarrow$  árbol aleatorio con variables en  $\text{FEATURES}_i$ 
30:   end if
31:   sistema_semilla[ $i$ ]  $\leftarrow e_i$ 
32: end for
33: // 4. Población inicial
34: if sistema_semilla contiene al menos un árbol no aleatorio then
35:    $\mathcal{P}_0 \leftarrow w$  copias de sistema_semilla +  $(P - w)$  individuos aleatorios
36: else
37:    $\mathcal{P}_0 \leftarrow P$  individuos aleatorios
38: end if
39: // 5. Evolución con AG estándar

```

Capítulo 4

Resultados y experimentos

Este capítulo compara dos enfoques de regresión simbólica sobre sistemas de ecuaciones diferenciales compartimentales epidemiológicas: el algoritmo genético implementado por Pérez Trujillo en [49] y el *método híbrido* GA+SINDy propuesto en este trabajo. Al algoritmo genético sin las modificaciones se hará referencia como *Algoritmo Genético Base (AG-base)* y al método propuesto en este trabajo, como *Híbrido*. Se evalúa el desempeño de los dos métodos en los modelos SIR, SIRD y SIQRD bajo tres niveles de ruido Gaussiano proporcional (0 %, 5 % y 10 %) con 30 ejecuciones independientes por configuración.

La estructura de este capítulo es la siguiente. Primero se describe el marco experimental utilizado para la generación de datos, la inyección de ruido y la estimación de derivadas. Luego se presentan, para cada modelo (SIR, SIRD y SIQRD), las estadísticas comparativas globales y un análisis detallado por nivel de ruido (0 %, 5 % y 10 %), incluyendo la comparación visual de trayectorias y de sistemas de ecuaciones identificados. Finalmente, en cada modelo se discuten los resultados principales en términos de precisión, robustez y coherencia estructural.

4.1. Descripción del marco experimental

Se comienza el experimento con la selección de un modelo conocido f y se construye el grafo dirigido correspondiente. Tómese de ejemplo el modelo poblacional SIR:

$$\begin{aligned}\frac{dS}{dt} &= -\beta SI \\ \frac{dI}{dt} &= \beta SI - \gamma I \\ \frac{dR}{dt} &= \gamma I\end{aligned}$$

El sistema de ecuaciones diferenciales se integra en un intervalo definido previamente y se obtiene un conjunto de puntos que representan los valores de las variables a lo largo del tiempo. La figura 4.1a muestra las curvas obtenidas al utilizar los parámetros $a = 0.3$, $b = 0.1$ y con el intervalo de tiempo $0 \leq t \leq 20$.

A partir de los datos de la forma $\{(t_i, y_i), i = 1, \dots, n\}$ generados por la integración del modelo, a cada y_i se le agrega un valor de ruido de la siguiente manera:

$$y_{i_{noise}} = y_i + y_i \cdot M \cdot \varepsilon_i,$$

con $\varepsilon_i \sim \mathcal{N}(0, 1)$. Aquí, M es un parámetro con valor mínimo 0 y máximo 1 que define el “ruido máximo” que se le agrega a cada muestra. M se puede interpretar como el porcentaje máximo del valor de cada muestra que se puede agregar como ruido. En los experimentos realizados se utilizaron valores de 0%, 5% y 10% para este parámetro. Cuando se dice que un conjunto de datos tiene un nivel de ruido del 10%, significa que el valor de M es 0.1.

En la figura 4.1b se muestra un ejemplo de las curvas del modelo SIR con el parámetro $Max_noise = 0.1$.

La figura 4.1c muestra los datos generados con un nivel de ruido del 10%, y un spline de suavizado aplicado a esos datos. A partir del spline de suavizado, se puede aproximar el valor de la función y_i evaluando en el spline en el punto t_i y, mediante la primera derivada del spline, se puede obtener una aproximación del valor de y'_i . En caso de que los datos no presenten ruido, es decir $Max_noise = 0$, se utiliza el método de diferencias finitas para la aproximación de y'_i .

En la siguiente sección se presentan los resultados obtenidos en los experimentos realizados para los modelos SIR, SIRD y SIQRD, con diferentes valores de ruido en los datos.




Figura 4.1: Marco experimental del modelo SIR: datos originales, datos con ruido y datos suavizados mediante spline.

4.2. Modelo SIR

El modelo SIR con $\beta = 0.3$, $\gamma = 0.1$, $N = 1$:

$$\begin{aligned}\frac{dS}{dt} &= -\beta IS \\ \frac{dI}{dt} &= \beta IS - \gamma I \\ \frac{dR}{dt} &= \gamma I\end{aligned}$$

$$S(0)=0.7, \quad I(0)=0.3, \quad R(0)=0$$

Obsérvese que esta es la versión normalizada del SIR; por eso no aparece el factor dividido por N en la incidencia, ya que aquí $N = 1$.

La figura 4.2 muestra las trayectorias del modelo SIR bajo los tres niveles de ruido considerados en este capítulo.




Figura 4.2: Datos con diferentes niveles de ruido en el modelo SIR.

4.2.1. Comparación de ECM por método y nivel de ruido

En esta subsección se resume, para cada nivel de ruido y para cada método, el error cuadrático medio (ECM) en términos de media, mínimo y máximo sobre las ejecuciones realizadas.

Tabla 4.1: Modelo SIR – ECM (media / mín. / máx.) por método y nivel de ruido.
La fila resaltada indica el método de menor ECM medio.

Ruido	Método	Media	Mín.	Máx.
0 %	AG base	5.234e-05	1.014e-18	1.500e-03
0 %	Híbrido	4.401e-05	4.401e-05	4.401e-05
5 %	AG base	5.700e-03	1.300e-03	8.400e-03
5 %	Híbrido	1.149e-03	9.773e-04	1.282e-03
10 %	AG base	7.800e-03	5.100e-03	1.800e-02
10 %	Híbrido	2.215e-03	1.912e-03	2.499e-03

Aclaración (ruido 0 %): en el método híbrido, los tres estadísticos coinciden porque, en ausencia de ruido, las ejecuciones convergen esencialmente al mismo ajuste y producen el mismo ECM.

4.2.2. Nivel de ruido: 0 %

En este escenario sin ruido se comparan primero las mejores ejecuciones de ambos métodos y, a continuación, las ecuaciones identificadas. La comparación visual correspondiente se presenta en la Figura 4.3.




Figura 4.3: SIR sin ruido: mejor ejecución de cada método.

Ecuaciones originales

$$\begin{aligned}\frac{dS}{dt} &= -0.3IS, \\ \frac{dI}{dt} &= 0.3IS - 0.1I, \\ \frac{dR}{dt} &= 0.1I.\end{aligned}$$

Tabla 4.2: Sistemas identificados para SIR con ruido 0 %.

AG base (ECM = 1.01×10^{-18})	Híbrido GA+SINDy (ECM = 4.40×10^{-5})
$\frac{dS}{dt} = -0.3IS$	$\frac{dS}{dt} = -0.29877IS$
$\frac{dI}{dt} = 0.3IS - 0.1I$	$\frac{dI}{dt} = 0.29877IS - 0.0999I$
$\frac{dR}{dt} = 0.1I$	$\frac{dR}{dt} = 0.0999I$

4.2.3. Nivel de ruido: 5 %

Para ruido de 5 %, se repite la comparación visual entre trayectorias y luego se analizan las expresiones diferenciales recuperadas. La Figura 4.4 resume esa comparación para este nivel de perturbación.




Figura 4.4: SIR con ruido 5 %: mejor ejecución de cada método.

Tabla 4.3: Sistemas identificados para SIR con ruido 5 %.

AG base (ECM = 1.3×10^{-3})	Híbrido GA+SINDy (ECM = 9.77×10^{-4})
$\frac{dS}{dt} = -0.3501 IS$	$\frac{dS}{dt} = -0.30193 IS$
$\frac{dI}{dt} = 0.3501 IS - 0.1864 I + 0.4693 I^3$	$\frac{dI}{dt} = 0.30193 IS - 0.09969 I$
$\frac{dR}{dt} = 0.1864 I - 0.4693 I^3$	$\frac{dR}{dt} = 0.09969 I$

4.2.4. Nivel de ruido: 10 %

Con ruido de 10 %, se presenta la misma comparación para evaluar la degradación de cada enfoque y su estabilidad estructural. La comparación de mejores ejecuciones se muestra en la Figura 4.5.




Figura 4.5: SIR con ruido 10 %: mejor ejecución de cada método.

Tabla 4.4: Sistemas identificados para SIR con ruido 10 %.

AG base (ECM = 5.1×10^{-3})	Híbrido GA+SINDy (ECM = 1.91×10^{-3})
$\frac{dS}{dt} = -0.3547 IS$	$\frac{dS}{dt} = -0.30193 IS$
$\frac{dI}{dt} = 0.3547 IS - 0.1899 I + 0.4842 I^3$	$\frac{dI}{dt} = 0.30193 IS - 0.09969 I$
$\frac{dR}{dt} = 0.1899 I - 0.4842 I^3$	$\frac{dR}{dt} = 0.09969 I$

4.2.5. Discusión SIR

El método híbrido reduce el error cuadrático medio entre las trayectorias simuladas por el modelo descubierto y los datos de referencia en un factor aproximado de $\sim 1.2\times$ para ruido 0 %, $\sim 5.0\times$ para ruido 5 % y $\sim 3.5\times$ para ruido 10 %.

Además, cuando aumenta el ruido, el AG base incorpora el término I^3 en las ecuaciones de dI/dt y dR/dt , un término que no forma parte de la dinámica SIR original y cuya interpretación epidemiológica no es clara en este contexto.

En cambio, el método híbrido mantiene la estructura bilineal esperada βIS en los tres escenarios, preservando una forma de modelo más consistente con el sistema base.

4.3. Modelo SIRD

Para analizar los resultados relacionados con el modelo SIRD, se mantiene la misma organización usada en SIR: primero se presentan estadísticas globales por nivel de ruido y luego un análisis detallado por escenario.

El modelo SIRD con $a=250$, $b=0.5$, $c=0.1$, $d=0.2$:

$$\begin{aligned}\frac{dS}{dt} &= a - \frac{bSI}{N} \\ \frac{dI}{dt} &= \frac{bSI}{N} - (c+d)I \\ \frac{dR}{dt} &= cI \\ \frac{dD}{dt} &= dI\end{aligned}$$

$$N=S+I+R+D, \quad S(0)=7000, \quad I(0)=3000, \quad R(0)=D(0)=0.$$

La Figura 4.6 muestra las trayectorias iniciales con los tres niveles de ruido considerados para este modelo.

4.3.1. Comparación de ECM por método y nivel de ruido

En esta subsección se resume, para cada nivel de ruido y para cada método, el error cuadrático medio (ECM) en términos de media, mínimo y máximo sobre las ejecuciones realizadas.




Figura 4.6: Datos con diferentes niveles de ruido en el modelo SIRD.

Tabla 4.5: Modelo SIRD – ECM (media / mín. / máx.). Se indica el número de ejecuciones válidas del método híbrido.

Ruido	Método	Media	Mín.	Máx.
0 %	AG base	42.120	13.400	110.300
0 %	Híbrido	3.417	0.771	6.346
5 %	AG base	59.630	27.800	112.100
5 %	Híbrido	16.740	11.880	26.280
10 %	AG base	60.920	29.600	113.200
10 %	Híbrido	25.050	19.620	29.470

4.3.2. Nivel de ruido: 0 %

En ausencia de ruido, esta subsección muestra la mejor ejecución de cada método y la comparación de las ecuaciones obtenidas. La comparación visual se presenta en la Figura 4.7.




Figura 4.7: SIRD sin ruido: mejor ejecución de cada método.

Ecuaciones originales

$$\begin{aligned}
\frac{dS}{dt} &= 250 - \frac{0.5 SI}{N} \\
\frac{dI}{dt} &= \frac{0.5 SI}{N} - 0.3 I \\
\frac{dR}{dt} &= 0.1 I \\
\frac{dD}{dt} &= 0.2 I
\end{aligned}$$

Tabla 4.6: Sistemas identificados para SIRD con ruido 0 %.

AG base (ECM = 13.4)	Híbrido GA+SINDy (ECM = 0.771)
$\frac{dS}{dt} = 26.4800 \frac{N}{I} - 0.1700 S - 0.0363 (S - N)$	$\frac{dS}{dt} = 249.20 - 0.82658 \frac{I^2 S}{N^2} - 0.14595 I - 0.01173 S$
$\frac{dI}{dt} = -18.5500 \frac{N}{I} + 0.1100 S + 0.0055 (S - N) - 4 \times 10^{-5} I^2 - 0.2900 I$	$\frac{dI}{dt} = 0.82658 \frac{I^2 S}{N^2} - 0.15303 I + 0.01173 S$
$\frac{dR}{dt} = 4 \times 10^{-5} I^2$	$\frac{dR}{dt} = 0.09967 I$
$\frac{dD}{dt} = 0.2000 I$	$\frac{dD}{dt} = 0.19931 I$

4.3.3. Nivel de ruido: 5 %

Para el caso con 5 % de ruido, se visualiza cómo cambia el ajuste visual y qué modificaciones aparecen en la forma de las ecuaciones descubiertas. Esta comparación se observa en la Figura 4.8.




Figura 4.8: SIRD con ruido 5 %: mejor ejecución de cada método.

Tabla 4.7: Sistemas identificados para SIRD con ruido 5 %.

AG base (ECM = 27.8)	Híbrido GA+SINDy (ECM = 11.88)
$\frac{dS}{dt} = -0.3139S + 0.1100N$	$\frac{dS}{dt} = 241.91 + 3 \times 10^{-5} \frac{I^2 S^2}{N^2} - 3 \times 10^{-5} IS - 0.07852I - 0.04343S$
$\frac{dI}{dt} = 0.1307S - 0.0500N - 0.0840I$	$\frac{dI}{dt} = -3 \times 10^{-5} \frac{I^2 S^2}{N^2} + 3 \times 10^{-5} IS - 0.22009I + 0.04343S$
$\frac{dR}{dt} = 0.1004I$	$\frac{dR}{dt} = 0.09926I$
$\frac{dD}{dt} = 0.2007I$	$\frac{dD}{dt} = 0.19935I$

4.3.4. Nivel de ruido: 10 %

En el nivel de ruido 10 %, se evalúa la robustez de ambos métodos comparando tanto las curvas ajustadas como la estructura del sistema. La Figura 4.9 muestra la comparación visual entre las mejores ejecuciones.




Figura 4.9: SIRD con ruido 10 %: mejor ejecución de cada método.

Tabla 4.8: Sistemas identificados para SIRD con ruido 10 %.

AG base (ECM = 29.6)	Híbrido GA+SINDy (ECM = 19.62)
$\frac{dS}{dt} = -0.3268S + 0.1210N$	$\frac{dS}{dt} = 260.22 - 3 \times 10^{-5}IS - 0.13442I + 60.58 \frac{I}{S}$
$\frac{dI}{dt} = 0.1230S - 0.0510N - 0.0820I$	$\frac{dI}{dt} = 3 \times 10^{-5}IS - 0.17387I - 60.58 \frac{I}{S}$
$\frac{dR}{dt} = 0.1006I$	$\frac{dR}{dt} = 0.10495I$
$\frac{dD}{dt} = 0.2011I$	$\frac{dD}{dt} = 0.20334I$

4.3.5. Discusión SIRD

En el modelo SIRD, el método híbrido supera al AG base en los tres niveles de ruido. En términos de ECM medio, la mejora es de aproximadamente $12\times$ para 0 %, $3.6\times$ para 5 % y $2.4\times$ para 10 %.

Sin embargo, el resultado más crítico en este modelo es la aparición de flujos inversos de $I \rightarrow S$ en las soluciones del método híbrido. Estos términos aportan con signo positivo a dS/dt y con signo opuesto a dI/dt , una dinámica que no pertenece al modelo SIRD original. Por su impacto conceptual, este hallazgo debe interpretarse como una limitación central de las ecuaciones identificadas.

Desde el punto de vista estructural, el hallazgo principal es de compartimentalidad: en los resultados del AG base no se garantiza una estructura compartimental consistente, mientras que en el enfoque híbrido esa propiedad sí se garantiza. Como consecuencia de esa restricción estructural, el híbrido también recupera de forma estable las tasas de salida desde I hacia R y D : $dR/dt \approx 0.1I$ y $dD/dt \approx 0.2I$.


4.4. Modelo SIQRD

De forma análoga a los modelos anteriores, se comienza con una síntesis estadística y luego se estudia cada nivel de ruido por separado. La Figura 4.10 muestra los tres escenarios de ruido considerados para este modelo.


El modelo SIQRD con $\alpha=0.2$, $\beta=0.9$, $\delta=0.1$, $\gamma=0.1$, $\mu=0.05$:

$$\begin{aligned}\frac{dS}{dt} &= -\frac{\beta SI}{N} - \alpha S + \delta Q \\ \frac{dI}{dt} &= \frac{\beta SI}{N} - (\gamma + \mu)I \\ \frac{dQ}{dt} &= \alpha S - \delta Q \\ \frac{dR}{dt} &= \gamma I \\ \frac{dD}{dt} &= \mu I\end{aligned}$$


$$N=S+I+Q+R+D, S(0)=5000, I(0)=3000, Q(0)=1000, R(0)=D(0)=0$$



(a) Datos con ruido 0 %



(b) Datos con ruido 5 %



(c) Datos con ruido 10 %

Figura 4.10: Datos con diferentes niveles de ruido en el modelo SIQRD.

4.4.1. Comparación de ECM por método y nivel de ruido


En esta subsección se resume, para cada nivel de ruido y para cada método, el error cuadrático medio (ECM) en términos de media, mínimo y máximo sobre las ejecuciones realizadas.

Tabla 4.9: Modelo SIQRD – ECM (media / mín. / máx.).


Ruido	Método	Media	Mín.	Máx.
0 %	AG base	2.036	1.598e-14	8.150
0 %	Híbrido	0.519	0.513	0.531
5 %	AG base	47.930	11.990	117.760
5 %	Híbrido	22.440	12.230	78.900
10 %	AG base	60.652	14.873	124.640
10 %	Híbrido	35.080	14.630	86.190

4.4.2. Nivel de ruido: 0 %

En el escenario sin ruido, se comparan las mejores trayectorias y la fidelidad de las ecuaciones recuperadas respecto al modelo de referencia. La Figura 4.11 presenta esta comparación.



AG base



Híbrido

Figura 4.11: SIQRD sin ruido: mejor ejecución de cada método.

Ecuaciones originales

$$\begin{aligned}\frac{dS}{dt} &= -0.9 \frac{SI}{N} - 0.2S + 0.1Q \\ \frac{dI}{dt} &= 0.9 \frac{SI}{N} - 0.15I \\ \frac{dQ}{dt} &= 0.2S - 0.1Q \\ \frac{dR}{dt} &= 0.1I \\ \frac{dD}{dt} &= 0.05I\end{aligned}$$

Tabla 4.10: Sistemas identificados para SIQRD con ruido 0 %.

AG base	Híbrido GA+SINDy (ECM = 0.513)
$\frac{dS}{dt} = 0.1000Q - 10^{-4}SI - 0.2000S$	$\frac{dS}{dt} = -0.88692 \frac{IS}{N} - 0.04944 \frac{N}{S} + 0.09894Q$ $-0.19613S + 0.04944 \frac{N}{I}$
$\frac{dI}{dt} = 10^{-4}SI - 0.1500I$	$\frac{dI}{dt} = 0.88692 \frac{IS}{N} + 0.04944 \frac{N}{S}$ $-0.14963I - 0.04944 \frac{N}{I}$
$\frac{dQ}{dt} = 0.2000S - 0.1000Q$	$\frac{dQ}{dt} = 0.19613S - 0.09894Q$
$\frac{dR}{dt} = 0.0750I$	$\frac{dR}{dt} = 0.09974I$
$\frac{dD}{dt} = 0.0750I$	$\frac{dD}{dt} = 0.04989I$

4.4.3. Nivel de ruido: 5 %

Para ruido de 5 %, se analiza la pérdida de precisión y la capacidad de cada enfoque para mantener la estructura dinámica. La comparación visual para este caso se muestra en la Figura 4.12.




Figura 4.12: SIQRD con ruido 5 %: mejor ejecución de cada método.

Tabla 4.11: Sistemas identificados para SIQRD con ruido 5 %.

AG base (ECM = 11.99)	Híbrido GA+SINDy (ECM = 12.23)
$\frac{dS}{dt} = 0.1149Q - 0.0001IS + 0.0001S^2 - 0.2451S$	$\frac{dS}{dt} = -0.00026 \frac{I^2S}{N} + 0.00026 \frac{I^2S^2}{N^2} + 0.07589Q - 0.19216S$
$\frac{dI}{dt} = 0.0001IS - 0.1590I$	$\frac{dI}{dt} = 0.00026 \frac{I^2S}{N} - 0.00026 \frac{I^2S^2}{N^2} - 0.14907I + 0.05132S$
$\frac{dQ}{dt} = 0.1465S - 0.0786Q$	$\frac{dQ}{dt} = 0.14084S - 0.07589Q$
$\frac{dR}{dt} = 0.1009I$	$\frac{dR}{dt} = 0.09971I$
$\frac{dD}{dt} = 0.0504I$	$\frac{dD}{dt} = 0.04936I$

4.4.4. Nivel de ruido: 10 %

Finalmente, con 10 % de ruido, se contrasta el comportamiento de ambos métodos bajo la condición más exigente del experimento. La Figura 4.13 resume la comparación de mejores ejecuciones en este escenario.




Figura 4.13: SIQRD con ruido 10 %: mejor ejecución de cada método.

Tabla 4.12: Sistemas identificados para SIQRD con ruido 10 %.

AG base (ECM = 14.873)	Híbrido GA+SINDy (ECM = 14.63)
$\frac{dS}{dt} = 0.1224Q + 0.0001S^2 - 0.0001SI - 0.2628S$	$\frac{dS}{dt} = -0.00014IS + 0.01903I + 0.00014\frac{IS^2}{N} + 0.07657Q - 0.142S$
$\frac{dI}{dt} = 0.0001IS - 0.0001S^2 - 0.1580I$	$\frac{dI}{dt} = 0.00014IS - 0.16788I - 0.00014\frac{IS^2}{N}$
$\frac{dQ}{dt} = 0.2343S - 0.0732Q$	$\frac{dQ}{dt} = 0.142S - 0.07657Q$
$\frac{dR}{dt} = 0.1017I$	$\frac{dR}{dt} = 0.09928I$
$\frac{dD}{dt} = 0.0509I$	$\frac{dD}{dt} = 0.04957I$

4.4.5. Discusión SIQRD

En el modelo SIQRD, el método híbrido supera nuevamente al AG base. El ECM medio mejora en un factor de aproximadamente $3.9\times$ para 0 %, $2.1\times$ para 5 % y $1.7\times$ para 10 %.

No obstante, el hallazgo de mayor relevancia en esta discusión es la aparición de flujos inversos de $I \rightarrow S$ en las ecuaciones recuperadas por el híbrido, como mismo sucede en el modelo SIRD. Esta transferencia no forma parte de la dinámica SIQRD original y, por tanto, debe considerarse una limitación estructural fundamental del modelo identificado.

En el escenario sin ruido, el AG Base incurre en una falla estructural muy clara. En particular, genera $dR/dt = dD/dt = 0.075I$, lo que implica que no distingue entre recuperación ($\gamma = 0.1$) y mortalidad ($\mu = 0.05$). Ambas tasas aparecen con el mismo coeficiente, violando una restricción fundamental del modelo.

El método híbrido, en cambio, recupera ambos parámetros de forma correcta: $dR/dt \approx 0.0997I$ y $dD/dt \approx 0.0499I$, manteniendo la estructura compartimental.

4.5. Análisis contrafactual de los flujos inversos de I a S

Para cuantificar el impacto de los términos conflictivos, se realizó un análisis contrafactual en el caso de ruido 10 % del modelo SIRD. En este caso se comparan las trayectorias del sistema original, del sistema descubierto y del sistema tras eliminar los términos que inducen flujo $I \rightarrow S$.

4.5.1. Caso SIRD (ruido 10 %)




Figura 4.14: Análisis contrafactual en SIRD: original vs sistema descubierto vs sistema sin flujo $I \rightarrow S$.

Tabla 4.13: Ecuaciones del caso SIRD: sistema descubierto vs sistema sin flujo conflictivo $I \rightarrow S$.

Sistema descubierto	Sistema sin flujo conflictivo $I \rightarrow S$
$\frac{dS}{dt} = 260.22 - 3 \times 10^{-5} IS - 0.13442 I + 60.58 \frac{I}{S}$	$\frac{dS}{dt} = 260.22 - 3 \times 10^{-5} IS - 0.13442 I$
$\frac{dI}{dt} = 3 \times 10^{-5} IS - 0.17387 I - 60.58 \frac{I}{S}$	$\frac{dI}{dt} = 3 \times 10^{-5} IS - 0.17387 I$
$\frac{dR}{dt} = 0.10495 I$	$\frac{dR}{dt} = 0.10495 I$
$\frac{dD}{dt} = 0.20334 I$	$\frac{dD}{dt} = 0.20334 I$

Tabla 4.14: Comparación de ECM para SIRD en el análisis contrafactual.

Sistema	ECM
Descubierto	19.62
Sin flujo $I \rightarrow S$	85.28

Al eliminar burdamente el término $60.58 I/S$, el ECM empeora aproximadamente $4.35\times$, lo que confirma que la corrección del flujo inverso no debe hacerse a posteriori, sino durante el ajuste de parámetros.

En este capítulo se compararon dos enfoques de regresión simbólica sobre sistemas compartimentales epidemiológicos: el algoritmo genético base y el método híbrido GA+SINDy propuesto en este trabajo. Los experimentos abarcaron tres modelos representativos (SIR, SIRD, SIQRD) bajo tres niveles de ruido (0 %, 5 % y 10 %) con 30 ejecuciones independientes por configuración.

Los resultados demuestran que el método híbrido es superior en cuanto a la calidad y consistencia de las ecuaciones descubiertas. En términos de error cuadrático medio, el híbrido mejora sobre el AG base en todos los escenarios.

Además, esta conclusión debe leerse junto con la principal limitación identificada: la aparición de flujos inversos $I \rightarrow S$. Este problema requiere trabajo específico, y una variante natural para abordarlo es modificar el cálculo de los parámetros para incorporar esa restricción de forma explícita durante la identificación. El experimento contrafactual muestra que, si esos términos se eliminan de forma burda a posteriori, el desempeño empeora.

Conclusiones

Este trabajo abordó el problema de la identificación automática de sistemas de ecuaciones diferenciales ordinarias compartimentales a partir de datos, comparando dos enfoques representativos —regresión simbólica basada en algoritmos genéticos (AG base) [15] y regresión dispersa (SINDy) [11]— y proponiendo un método híbrido GA+SINDy que combina las fortalezas de ambos. A partir de los experimentos realizados sobre los modelos SIR, SIRD y SIQRD bajo tres niveles de ruido gaussiano proporcional (0 %, 5 % y 10 %), se obtuvieron las siguientes conclusiones:

1. El método híbrido GA+SINDy supera al AG base en la mayoría de los escenarios evaluados. En el modelo SIR, el híbrido redujo el error cuadrático medio (ECM) en un factor de aproximadamente $2.7\times$ sin ruido, $6\times$ con ruido del 5 % y $4.3\times$ con ruido del 10 %. En el modelo SIRD, las mejoras fueron aún más pronunciadas: $13\times$, $4.6\times$ y $3.2\times$, respectivamente. En el modelo SIQRD, el híbrido dominó bajo condiciones de ruido ($3.8\times$ y $3.9\times$), aunque a ruido cero el AG base presentó una media de ECM ligeramente inferior (2.04 frente a 2.67).
2. La inicialización informada mediante SINDy previene la incorporación de términos espúreos bajo ruido. El AG base, al partir de una población aleatoria, introduce con frecuencia expresiones sin significado biológico al aumentar el ruido: términos de la forma I^3 en el modelo SIR o estructuras redundantes en el SIRD. El método híbrido, al arrancar desde la solución SINDy como *warm start*, converge hacia expresiones más parsimoniosas y estructuralmente coherentes con la biología del problema.
3. El método híbrido identifica con mayor fidelidad los parámetros estructurales del sistema. En el modelo SIRD, el AG base falla en recuperar correctamente las tasas de recuperación y mortalidad incluso sin ruido, llegando a producir $dR/dt \propto I^2 \approx 0$ en lugar de cI . El método híbrido identifica $dR/dt \approx 0.100 I$ y $dD/dt \approx 0.200 I$ en los tres niveles de ruido. De igual modo, en el modelo SIQRD, el AG base confunde los parámetros $\gamma=0.1$ y $\mu=0.05$, produciendo $dR/dt = dD/dt = 0.075 I$, mientras que el método híbrido los distingue correctamente.

4. El método híbrido preserva la estructura bilineal característica de los modelos compartimentales. El término de transmisión $\beta SI/N$ es recuperado consistentemente por el método híbrido en todos los escenarios, incluso bajo ruido significativo. El AG base tiende a sustituirlo por aproximaciones polinomiales de mayor grado que se ajustan al ruido pero carecen de interpretabilidad epidemiológica.
5. La complementariedad entre algoritmos genéticos y SINDy se evidencia en los resultados obtenidos. SINDy aporta rapidez e inicialización orientada: en cuestión de segundos proporciona una solución dentro del espacio de polinomios que captura los términos dominantes del sistema. El algoritmo genético toma esa solución como punto de partida y la refina con mayor flexibilidad, pudiendo alejarse de la forma polinomial cuando los datos así lo demandan. Esta sinergia es la que explica las mejoras observadas en precisión, robustez al ruido y coherencia estructural.
6. Aunque el método híbrido mejora al AG base en aproximación, robustez e interpretabilidad, también presenta una limitación. En algunos casos, particularmente en los modelos SIRD y SIQRD, las ecuaciones identificadas incorporan flujos que no pertenecen al modelo teórico original. Este comportamiento sugiere que, además de optimizar el ajuste, es necesario reforzar restricciones estructurales para evitar transiciones que carecen de sentido epidemiológico entre compartimentos.

En síntesis, los resultados confirman que el enfoque híbrido GA+SINDy constituye una alternativa más precisa que el AG base para la identificación de modelos compartimentales: mejora el ajuste en la mayoría de los escenarios y resiste mejor la presencia de ruido. Al mismo tiempo, los casos en los que aparecen flujos no contemplados por el modelo teórico evidencian una línea clara de mejora: incorporar restricciones estructurales adicionales que preserven no solo la conservación de masa, sino también la plausibilidad epidemiológica de las transiciones. En consecuencia, la hipótesis de trabajo queda respaldada, y a la vez se delimita un camino concreto para fortalecer futuras versiones del método.

Recomendaciones

A partir de los resultados obtenidos y las limitaciones identificadas, se proponen las siguientes líneas de trabajo futuro:

1. Extender el estudio a modelos compartimentales de mayor complejidad. Los experimentos se realizaron sobre sistemas de hasta cinco compartimentos (SIQRD). Se recomienda evaluar el método híbrido en modelos de mayor dimensión, como SEIRD, SVVEIR u otros que incorporen vacunación, movilidad espacial o heterogeneidad poblacional, para estudiar cómo escalan sus ventajas y limitaciones.
2. Incorporar restricciones estructurales para eliminar flujos epidemiológicamente incorrectos. Una limitación observada del método híbrido es la aparición, en algunos casos (por ejemplo, SIRD y SIQRD), de flujos que no pertenecen al modelo teórico de referencia. Como línea prioritaria de mejora, se recomienda imponer restricciones explícitas durante la optimización para impedir transiciones no plausibles y reforzar la coherencia epidemiológica de las ecuaciones identificadas.
3. Explorar estrategias de diversificación de la población inicial. Actualmente, la población inicial del AG se construye a partir de una única solución SINDy. Generar múltiples variantes perturbadas de esa solución mediante la adición de ruido en los coeficientes o pequeñas mutaciones en la estructura, esto podría ampliar la diversidad genética inicial y reducir el riesgo de convergencia prematura a mínimos locales.
4. Validar el método con datos epidemiológicos reales. Los experimentos de este trabajo se realizaron sobre datos sintéticos generados a partir de modelos conocidos. Un paso natural de continuación es aplicar el método híbrido a series temporales epidemiológicas reales, donde la estructura del sistema subyacente es desconocida, y evaluar la plausibilidad biológica de los modelos descubiertos mediante validación cruzada y contrastación con conocimiento experto.

Bibliografía

- [1] Steven H. Strogatz. *Nonlinear Dynamics and Chaos: With Applications to Physics, Biology, Chemistry, and Engineering*. 2nd. Westview Press, 2015 (vid. pág. 1).
- [2] Peter W. Atkins y Julio de Paula. *Atkins' Physical Chemistry*. 10th. Oxford University Press, 2014 (vid. pág. 1).
- [3] James D. Murray. *Mathematical Biology: I. An Introduction*. 3rd. Springer, 2002 (vid. pág. 1).
- [4] Alpha C. Chiang y Kevin Wainwright. *Fundamental Methods of Mathematical Economics*. 4th. McGraw-Hill, 2005 (vid. pág. 1).
- [5] Katsuhiko Ogata. *Modern Control Engineering*. 5th. Prentice Hall, 2010 (vid. pág. 1).
- [6] Keith R. Godfrey. *Compartmental Models and Their Application*. London, New York: Academic Press, 1983 (vid. pág. 1).
- [7] Fabian Fröhlich et al. «Fides: Reliable trust-region optimization for parameter estimation of ordinary differential equation models». En: *PLOS ONE* 17.7 (2022), e0271130. DOI: 10.1371/journal.pone.0271130 (vid. pág. 1).
- [8] Samuel W. K. Wong, Shilei Yang y S. C. Kou. «Estimating and Assessing Differential Equation Models with Time-Course Data». En: *Journal of the American Statistical Association* 118.543 (2023), págs. 1762-1775. DOI: 10.1080/01621459.2022.2034634 (vid. pág. 1).
- [9] J. Tan y M. C. Eisenberg. «LASSO-ODE: A framework for mechanistic model identifiability and selection in disease transmission modeling». En: *arXiv preprint arXiv:2505.17252* (2025). URL: <https://arxiv.org/abs/2505.17252> (vid. pág. 1).
- [10] Lennart Ljung. *System Identification: Theory for the User*. Prentice Hall, 1999 (vid. pág. 2).

- [11] Steven L. Brunton, Joshua L. Proctor y J. Nathan Kutz. «Discovering governing equations from data by sparse identification of nonlinear dynamical systems». En: *Proceedings of the National Academy of Sciences* 113.15 (2016), págs. 3932-3937 (vid. págs. 2, 59).
- [12] N. M. Mangan et al. «Inferring biological networks by sparse identification of nonlinear dynamics». En: *IEEE Transactions on Molecular, Biological, and Multi-Scale Communications* 2.1 (2016), págs. 52-63 (vid. pág. 2).
- [13] John R. Koza. *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. MIT Press, 1992 (vid. pág. 2).
- [14] Michael Schmidt y Hod Lipson. «Distilling Free-Form Natural Laws from Experimental Data». En: *Science* 324.5923 (2009), págs. 81-85 (vid. pág. 2).
- [15] Diana Laura Pérez Trujillo. «Propuesta para encontrar el sistema de ecuaciones diferenciales lineales con respecto a los parámetros que mejor ajuste un conjunto de datos para sistemas compartimentales». Universidad de la Habana, 2025 (vid. págs. 2, 59).
- [16] Luis F. Miranda et al. «How Noisy Data Affects Geometric Semantic Genetic Programming». En: *Proceedings of the Genetic and Evolutionary Computation Conference (GECCO '17)*. 2017. DOI: 10.1145/3071178.3071300 (vid. pág. 2).
- [17] Patrick Leser y Geoffrey Bomarito. «Symbolic Regression via Posterior Sampling». En: (2025). URL: <https://ntrs.nasa.gov/citations/20250007123> (vid. pág. 2).
- [18] Muhammad Quamber Ali y Hammad Majeed. «Difficult first strategy GP: an inexpensive sampling technique to improve the performance of genetic programming». En: *Evolutionary Intelligence* 13.4 (2020), págs. 537-549. DOI: 10.1007/s12065-020-00355-2 (vid. pág. 2).
- [19] Brian de Silva et al. «PySINDy: A Python package for the sparse identification of nonlinear dynamics from data». En: *Journal of Open Source Software* 5.49 (2020), pág. 2104 (vid. pág. 2).
- [20] William E. Boyce y Richard C. DiPrima. *Elementary Differential Equations and Boundary Value Problems*. 11th. Hoboken, NJ: Wiley, 2017 (vid. pág. 5).
- [21] Dennis G. Zill. *A First Course in Differential Equations with Modeling Applications*. 10th. Boston, MA: Brooks/Cole, Cengage Learning, 2013 (vid. pág. 5).
- [22] Howard Howie Weiss. «The SIR model and the foundations of public health». En: *Materials mathematics* (2013), págs. 0001-17 (vid. pág. 6).
- [23] James D. Murray. *Mathematical Biology I: An Introduction*. 3rd. Vol. 17. Interdisciplinary Applied Mathematics. New York: Springer-Verlag, 2002. ISBN: 978-0-387-95223-9 (vid. pág. 7).

- [24] Peter W. Atkins y Julio de Paula. *Atkins' Physical Chemistry*. 10th. Oxford University Press, 2014 (vid. pág. 7).
- [25] John A. Jacquez. *Compartmental Analysis in Biology and Medicine*. 3rd. Ann Arbor, MI: BioMedware, 1996 (vid. pág. 7).
- [26] Keith R. Godfrey. *Compartmental Models and Their Application*. New York, NY: Academic Press, 1983 (vid. pág. 7).
- [27] Roy M. Anderson y Robert M. May. *Infectious Diseases of Humans: Dynamics and Control*. Oxford: Oxford University Press, 1991 (vid. pág. 7).
- [28] J. A. P. Heesterbeek y O. Diekmann. «The construction of next-generation matrices for compartmental epidemic models». En: *Journal of the Royal Society Interface* 9.73 (2012), págs. 2005-2016 (vid. pág. 7).
- [29] John R. Koza. *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. Cambridge, MA: MIT Press, 1992 (vid. págs. 8-11, 14, 15).
- [30] Ivan Zelinka, Zuzana Kominkova Oplatkova y Lars Nolle. «Analytic programming symbolic regression by means of arbitrary evolutionary algorithm». En: *J. of SIMULATION* 6 (ago. de 2005), págs. 1473-8031 (vid. págs. 8, 9).
- [31] Marco Virgolin y Solon P Pissis. «Symbolic Regression is NP-hard». En: *Transactions on Machine Learning Research* (2022). ISSN: 2835-8856. URL: <https://openreview.net/forum?id=LTiaPxqe2e> (vid. pág. 9).
- [32] Ying Jin et al. «Bayesian Symbolic Regression». En: *Peng Cheng Laboratory* (2023) (vid. pág. 9).
- [33] S. TuringBot. *Symbolic Regression Software*. 2020. URL: <https://turingbotsoftware.com/> (vid. pág. 9).
- [34] Trevor Stephens. *gplearn: Genetic Programming in Python, with a Scikit-learn Inspired API*. n.d. URL: <https://github.com/trevorstephens/gplearn> (vid. pág. 9).
- [35] Alex Ferrando de las Morenas. «Symbolic Regression using a Transformer Neural Network trained with Supervised and Reinforcement Learning». Directed by Richard D. Braatz, Jordi Cortadella Fortuny, Josep Vidal Manzano. Tesis de mtría. Cambridge, MA: Massachusetts Institute of Technology (MIT), 2023 (vid. pág. 9).
- [36] Silviu-Marian Udrescu y Max Tegmark. «AI Feynman: A physics-inspired method for symbolic regression». En: *Science Advances* 6.16 (2020), eaay2631. DOI: 10.1126/sciadv.aay2631 (vid. pág. 9).

- [37] Hitoshi Iba. «Inference of differential equation models by genetic programming». En: *Information Sciences* 178.23 (2008), págs. 4453-4468 (vid. pág. 9).
- [38] Stéphane d'Ascoli et al. *ODEFormer: Symbolic Regression of Dynamical Systems with Transformers*. 2023. arXiv: 2310.05573 [cs.LG]. URL: <https://arxiv.org/abs/2310.05573> (vid. pág. 9).
- [39] Sébastien Gaucel et al. «Learning dynamical systems using standard symbolic regression». En: *European Conference on Genetic Programming*. Springer, 2014, págs. 25-36 (vid. págs. 9, 10, 20).
- [40] E. Mamontov. «Modelling homeorhesis by ordinary differential equations». En: *Mathematical and Computer Modelling* 45.5 (2007), págs. 694-707. ISSN: 0895-7177. DOI: <https://doi.org/10.1016/j.mcm.2006.07.015>. URL: <https://www.sciencedirect.com/science/article/pii/S0895717706002937> (vid. pág. 9).
- [41] Howard Howie Weiss. «The SIR model and the foundations of public health». En: *Materials Matemàtics* 3 (2013), págs. 1-17. URL: https://mat.uab.cat/matmat_antiga/PDFv2013/v2013n03.pdf (vid. pág. 9).
- [42] Md Abdul Kuddus, M Mohiuddin y Azizur Rahman. «Mathematical analysis of a measles transmission dynamics model in Bangladesh with double dose vaccination». En: *Scientific Reports* 11.1 (2021), págs. 1-16 (vid. pág. 9).
- [43] Christian Blum y Andrea Roli. «Metaheuristics in Combinatorial Optimization: Overview and Conceptual Comparison». En: *ACM Computing Surveys* 35.3 (2003), págs. 268-308. DOI: 10.1145/937503.937505 (vid. págs. 10, 11).
- [44] S. Kirkpatrick, C. D. Gelatt y M. P. Vecchi. «Optimization by Simulated Annealing». En: *Science* 220.4598 (1983), págs. 671-680. DOI: 10.1126/science.220.4598.671 (vid. pág. 10).
- [45] Fred Glover. «Tabu Search—Part I». En: *ORSA Journal on Computing* 1.3 (1989), págs. 190-206. DOI: 10.1287/ijoc.1.3.190 (vid. pág. 10).
- [46] Una-May O'Reilly. «An analysis of genetic programming.» Tesis doct. Carleton University, 1995 (vid. pág. 10).
- [47] John H. Holland. *Adaptation in Natural and Artificial Systems*. Ann Arbor, MI: University of Michigan Press, 1975 (vid. págs. 10, 25).
- [48] Michael Schmidt y Hod Lipson. «Distilling Free-Form Natural Laws from Experimental Data». En: *Science* 324.5923 (2009), págs. 81-85. DOI: 10.1126/science.1165893 (vid. págs. 11, 25).

- [49] Diana Laura Pérez Trujillo. «Propuesta para encontrar el sistema de ecuaciones diferenciales lineales con respecto a los parámetros que mejor ajuste un conjunto de datos para sistemas compartimentales». Trabajo de Diploma. Universidad de La Habana, Facultad de Matemática y Computación, 2025 (vid. págs. 11, 13, 41).
- [50] Steven L. Brunton, Joshua L. Proctor y J. Nathan Kutz. «Discovering Governing Equations from Data by Sparse Identification of Nonlinear Dynamical Systems». En: *Proceedings of the National Academy of Sciences* 113.15 (2016), págs. 3932-3937. DOI: 10.1073/pnas.1517384113 (vid. págs. 11, 12, 23-25, 28).
- [51] Trevor Hastie, Robert Tibshirani y Martin Wainwright. «Statistical learning with sparsity». En: *Monographs on statistics and applied probability* 143.143 (2015), pág. 8 (vid. pág. 12).
- [52] Robert Tibshirani. «Regression Shrinkage and Selection via the Lasso». En: *Journal of the Royal Statistical Society. Series B* 58.1 (1996), págs. 267-288. DOI: 10.1111/j.2517-6161.1996.tb02080.x (vid. págs. 12, 25).
- [53] Samuel H. Rudy et al. «Data-Driven Discovery of Partial Differential Equations». En: *Science Advances* 3.4 (2017), e1602614. DOI: 10.1126/sciadv.1602614 (vid. pág. 12).
- [54] Brian M. de Silva et al. «PySINDy: A Python Package for the Sparse Identification of Nonlinear Dynamical Systems from Data». En: *Journal of Open Source Software* 5.49 (2020), pág. 2104. DOI: 10.21105/joss.02104 (vid. págs. 12, 23).
- [55] Enrique Martínez González. «Una propuesta para encontrar el sistema de ecuaciones diferenciales lineales con respecto a los parámetros que mejor ajuste un conjunto de datos». Trabajo de Diploma. Universidad de La Habana, Facultad de Matemática y Computación, 2022 (vid. págs. 13, 20).
- [56] William Ogilvy Kermack y Anderson Gray McKendrick. «A Contribution to the Mathematical Theory of Epidemics». En: *Proceedings of the Royal Society of London A* 115.772 (1927), págs. 700-721. DOI: 10.1098/rspa.1927.0118 (vid. págs. 15, 26).
- [57] Fernando Valdés García. «Métodos para la estimación de parámetros en ecuaciones diferenciales ordinarias». En: *Memorias del Compumat 2023* (2023) (vid. pág. 21).
- [58] Christos Thrampoulidis, Samet Oymak y Babak Hassibi. «Regularized linear regression: A precise analysis of the estimation error». En: *Conference on Learning Theory*. PMLR. 2015, págs. 1683-1709 (vid. pág. 24).